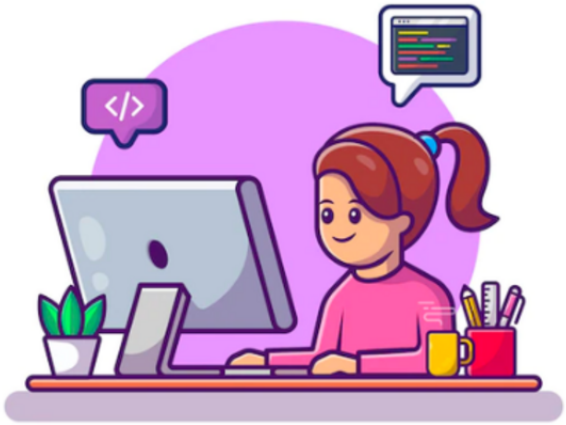
Filière de Big Data et Intelligence Artificielle
École Nationale des Sciences Appliquées de Tétouan

# Analyse des salaires en Data Science




**Groupe :**
EL ALAOUI SALEH Zouhair
GHOULAM Nouhaila
PROBI Nouhaila
FERGANI Insaf
HADI Sara

**Encadré par :**
Pr.BOUKROUH Ikhlass


**2025-2026**

# Table des matières


**1 Présentation du sujet** **3**
- 1.1 Introduction générale . . . 3
- 1.2 Objectifs du Projet . . . 3
- 1.3 Le jeu de données . . . 3
- 1.4 Description des variables . . . 5

**2 Visualisation Univariée** **6**
- 2.1 Variables quantitatives . . . 6
  - 2.1.1 Salaire en USD/an . . . 6
  - 2.1.2 Type de travail . . . 8
- 2.2 Variables qualitatives . . . 10
  - 2.2.1 Nom de spécialité . . . 10
  - 2.2.2 Pays de résidence . . . 11
- 2.3 Décisions . . . 13

**3 Visualisation Bivariée** **14**
- 3.1 Quantitative – Quantitative . . . 14
  - 3.1.1 Cas 1 : salary_in_usd vs remote_ratio . . . 14
  - 3.1.2 Cas 2 : salary_in_usd vs work_year . . . 15
- 3.2 Qualitative – Quantitative . . . 15
  - 3.2.1 Cas 3 : experience_level vs salary_in_usd . . . 15
  - 3.2.2 Cas 4 : company_size vs salary_in_usd . . . 16
  - 3.2.3 Cas 5 : employment_type vs salary_in_usd . . . 17
- 3.3 Qualitative – Qualitative . . . 18
  - 3.3.1 Cas 6 : experience_level vs company_size . . . 18
  - 3.3.2 Cas 7 : employment_type vs experience_level . . . 19
- 3.4 Décisions . . . 20

**4 Visualisation Multivariée** **21**
- 4.1 Visualiser les relations entre plusieurs variables . . . 21
  - 4.1.1 Scatter plot . . . 21
  - 4.1.2 Pairplot . . . 24
  - 4.1.3 Décisions . . . 26
- 4.2 Analyser les dépendances entre variables . . . 27
  - 4.2.1 Heatmap . . . 27
  - 4.2.2 Décision . . . 28
- 4.3 Comparer des groupes . . . 28
  - 4.3.1 Boxplot . . . 28
  - 4.3.2 Violin plot . . . 30
  - 4.3.3 Décisions . . . 31
- 4.4 Analyse des profils multivariés (Parallel Coordinates) . . . 31

4.4.1 Sans normalisation . . . 32
4.4.2 Après normalisation . . . 32
4.4.3 Echantillon . . . 33
4.4.4 Décisions . . . 33
4.5 Simplifier les données complexes . . . 33
4.5.1 ACP avec 2 composantes (2D) . . . 33
4.5.2 Visualisation avec 3 composantes (3D) . . . 34
4.5.3 Décisions . . . 36

**5 Visualisation Temporelle-Geospatiale 37**
5.1 visualisation Temporelle . . . 37
5.1.1 Suivre l'évolution d'une variable dans le temps . . . 37
5.1.2 Comparer plusieurs séries temporelles . . . 38
5.1.3 Mettre en évidence une tendance générale . . . 39
5.1.4 Détecter une saisonnalité ou des cycles . . . 41
5.1.5 Repérer des anomalies . . . 43
5.1.6 Analyser la fréquence et la répartition des événements dans le temps 43
5.1.7 Décisions . . . 44
5.2 visualisation Geopatiale . . . 44
5.2.1 Localiser des objets ou événements dans l'espace . . . 45
5.2.2 Comparer des valeurs entre plusieurs zones géographiques . . . 45
5.2.3 Représenter l'intensité d'un phénomène en chaque lieu . . . 46
5.2.4 Détecter des concentrations ou zones denses . . . 46
5.2.5 Montrer des déplacements entre pays . . . 47
5.2.6 Décisions . . . 47
5.3 Visualisation GeoTemporelle . . . 48
5.3.1 Carte pour une date . . . 48
5.3.2 Comparer plusieurs dates . . . 49
5.3.3 Courbe temporelle pour pays . . . 50
5.3.4 Décisions . . . 52

**6 Conclusion 53**

# Chapitre 1

# Présentation du sujet

## 1.1 Introduction générale

La Data Science est aujourd'hui un domaine en pleine expansion, porté par la transformation numérique des entreprises et l'explosion des volumes de données. Cette évolution a entraîné une forte demande pour les profils spécialisés, impactant directement les niveaux de rémunération dans ce secteur.

Dans ce contexte, l'analyse des salaires en Data Science devient essentielle pour comprendre les dynamiques du marché de l'emploi. Les rémunérations varient selon plusieurs facteurs tels que le niveau d'expérience, le type de contrat, la localisation géographique, la taille de l'entreprise ou encore le mode de travail (présentiel, hybride ou à distance).

L'objectif de ce projet est d'exploiter un ensemble de données réelles afin d'analyser ces facteurs à travers différentes techniques de visualisation. En combinant des approches univariées, bivariées, multivariées ainsi que des analyses temporelles et géospatiales, ce travail vise à extraire des informations pertinentes permettant de mieux comprendre les tendances du marché et d'orienter la prise de décision.

## 1.2 Objectifs du Projet

L'objectif principal de ce projet est d'analyser les salaires dans le domaine de la Data Science à l'aide de techniques de visualisation de données afin d'identifier les facteurs qui influencent la rémunération.

Plus précisément, ce projet vise à :

- Étudier la distribution des salaires et identifier les tendances générales
- Analyser l'impact des variables clés (expérience, type de contrat, taille de l'entreprise, localisation, remote ratio) sur le salaire
- Explorer les relations entre variables à travers des analyses bivariées et multivariées
- Examiner l'évolution des salaires dans le temps et selon les zones géographiques
- Identifier les variables les plus déterminantes dans la variation des salaires
- Transformer les résultats analytiques en recommandations stratégiques pour les entreprises et les professionnels

## 1.3 Le jeu de données

Le jeu de données **ds_salaries** disponible au lien suivant :
**https://www.kaggle.com/datasets/ruchi798/data-science-job-salaries**, contient

des informations relatives aux salaires des professionnels travaillant dans le domaine de la Data Science et de l'Intelligence Artificielle.

Il regroupe des observations provenant de plusieurs pays et années, permettant d'analyser l'impact de différents facteurs tels que le niveau d'expérience, le type de contrat, le poste occupé, la taille de l'entreprise, le pays de résidence ainsi que le mode de travail (présentiel, hybride ou télétravail).

La variable principale d'intérêt est **salary_in_usd**, qui représente le salaire converti en dollars américains afin de faciliter les comparaisons internationales.

Ce dataset permet ainsi d'étudier la structure du marché de l'emploi en Data Science et d'identifier les facteurs susceptibles d'influencer les niveaux de rémunération.

```
data.shape
```

(607, 12)

```
print(data.isnull().mean()*100)
```

| Variable | Valeur |
|---|---|
| Unnamed : 0 | 0.0 |
| work_year | 0.0 |
| experience_level | 0.0 |
| employment_type | 0.0 |
| job_title | 0.0 |
| salary | 0.0 |
| salary_currency | 0.0 |
| salary_in_usd | 0.0 |
| employee_residence | 0.0 |
| remote_ratio | 0.0 |
| company_location | 0.0 |
| company_size | 0.0 |

TABLE 1.1 – nombre de valeurs manquantes

```
data.nunique()
```

| Variable | Nombre de valeurs |
|---|---|
| Unnamed : 0 | 607 |
| work_year | 3 |
| experience_level | 4 |
| employment_type | 4 |
| job_title | 50 |
| salary | 272 |
| salary_currency | 17 |
| salary_in_usd | 369 |
| employee_residence | 57 |
| remote_ratio | 3 |
| company_location | 50 |
| company_size | 3 |

TABLE 1.2 – Nombre de valeurs par variable

## 1.4 Description des variables

### Variables numériques

— **work_year** : Année durant laquelle le salaire a été versé.
— **salary** : Salaire brut exprimé dans la devise locale.
— **salary_in_usd** : Salaire converti en dollars américains pour permettre la comparaison internationale.
— **remote_ratio** : Pourcentage de télétravail (0%, 50%, 100%).

### Variables catégorielles

— **experience_level** : Niveau d'expérience (Entry, Mid, Senior, Executive).
— **employment_type** : Type de contrat (temps plein, temps partiel, contrat, freelance).
— **job_title** : Intitulé du poste occupé.
— **salary_currency** : Devise utilisée pour exprimer le salaire.
— **employee_residence** : Pays de résidence de l'employé.
— **company_location** : Pays où l'entreprise est située.
— **company_size** : Taille de l'entreprise (petite, moyenne, grande).

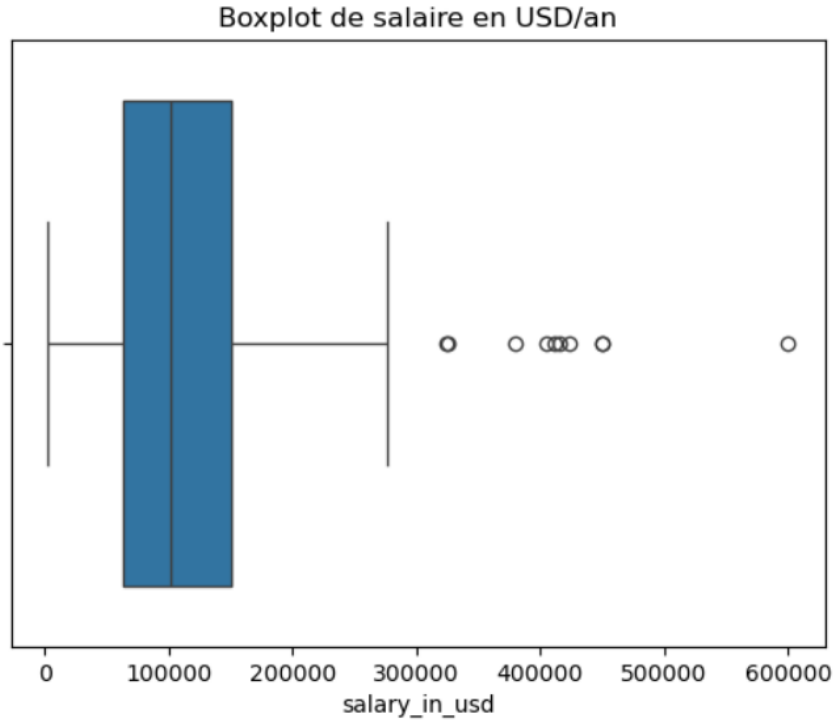
# Chapitre 2

# Visualisation Univariée

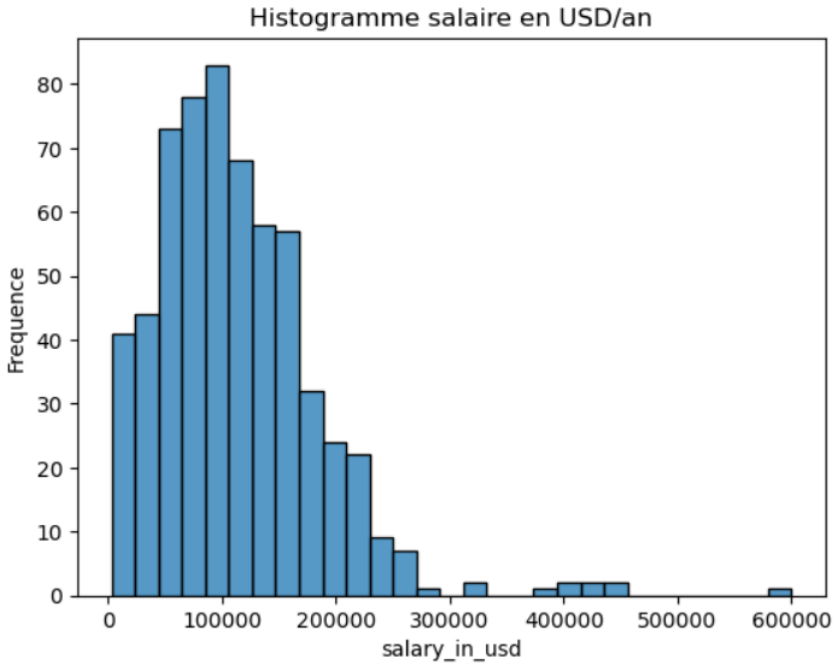
La visualisation univariée consiste à analyser chaque variable individuellement afin de comprendre sa distribution, sa dispersion et ses caractéristiques principales. Elle permet d'identifier les tendances générales, les valeurs extrêmes ainsi que la structure globale des données. Dans cette partie, nous utilisons différents graphiques tels que les histogrammes, boxplots et diagrammes en barres pour explorer les variables quantitatives et qualitatives.

## 2.1 Variables quantitatives

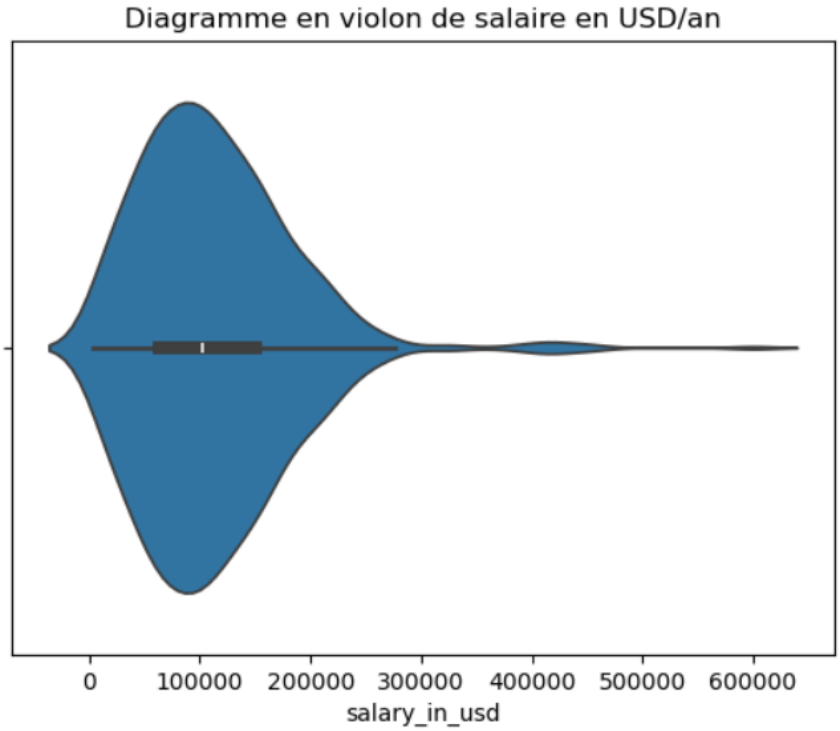
### 2.1.1 Salaire en USD/an




La boîte est concentrée entre environ 80 000 et 150 000 USD, avec une médiane située autour de 100 000 USD. Les moustaches s'étendent vers des valeurs plus faibles et plus élevées. On observe plusieurs points isolés à droite du graphique, correspondant à des valeurs élevées de salaire.




La majorité des observations est concentrée entre environ 50 000 et 150 000 USD, où les barres sont les plus hautes. La fréquence diminue progressivement lorsque le salaire augmente, et on observe quelques valeurs élevées au-delà de 300 000 USD, ce qui crée une longue queue vers la droite du graphique.

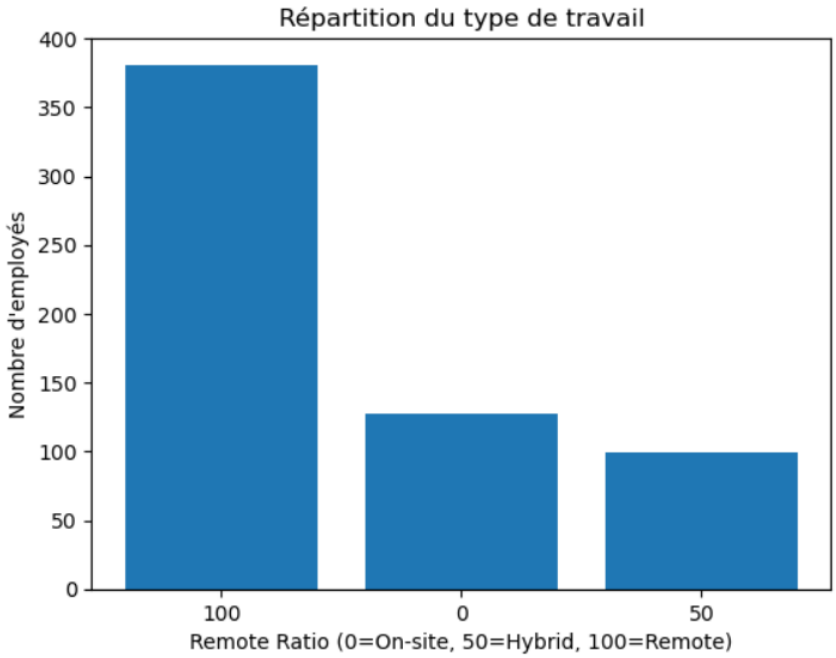



La partie la plus large du violon se situe autour de 80 000 à 150 000 USD, ce qui indique que la majorité des salaires est concentrée dans cette zone. La forme s'étend davantage vers les valeurs élevées, avec une longue partie fine à droite, montrant la présence de salaires élevés mais peu fréquents.

Les trois graphiques montrent que la majorité des salaires est concentrée entre 80 000 et 150 000 USD. Cependant, la distribution est asymétrique à droite, avec quelques salaires

très élevés qui augmentent la dispersion. Cela indique une concentration des revenus moyens et la présence de valeurs élevées peu fréquentes.

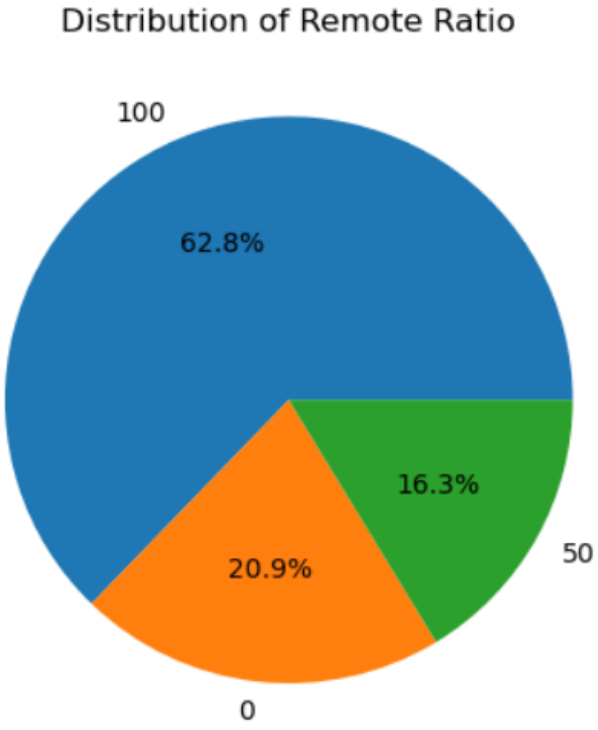
### 2.1.2 Type de travail



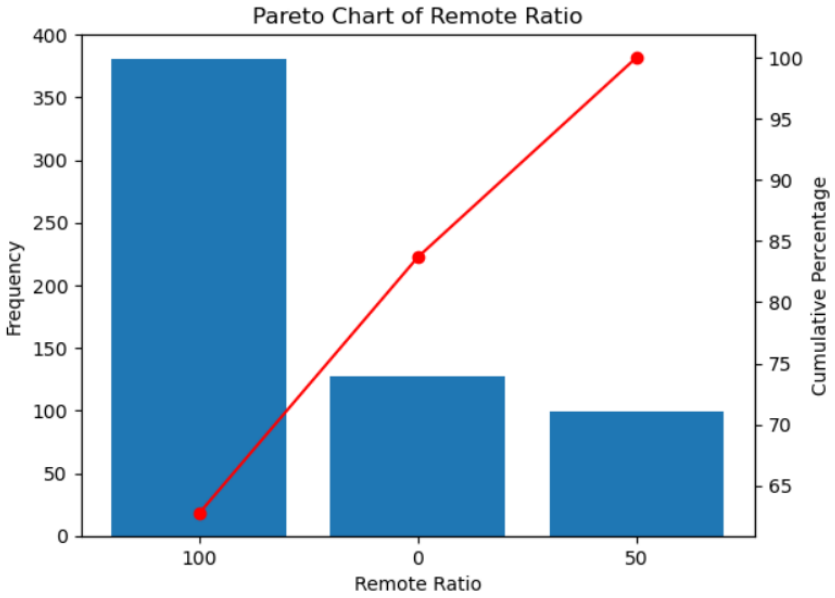

La catégorie 100 (Remote) est la plus élevée. Ensuite vient 0 (On-site). Enfin 50 (Hybrid).

La majorité des employés travaillent 100

Cela montre que : Le secteur de la Data Science est fortement orienté vers le télétravail.



Le diagramme circulaire montre que la majorité des employés travaillent entièrement à distance. Le travail sur site et hybride représentent une proportion plus faible. Cela confirme que le télétravail domine dans le domaine de la Data Science.

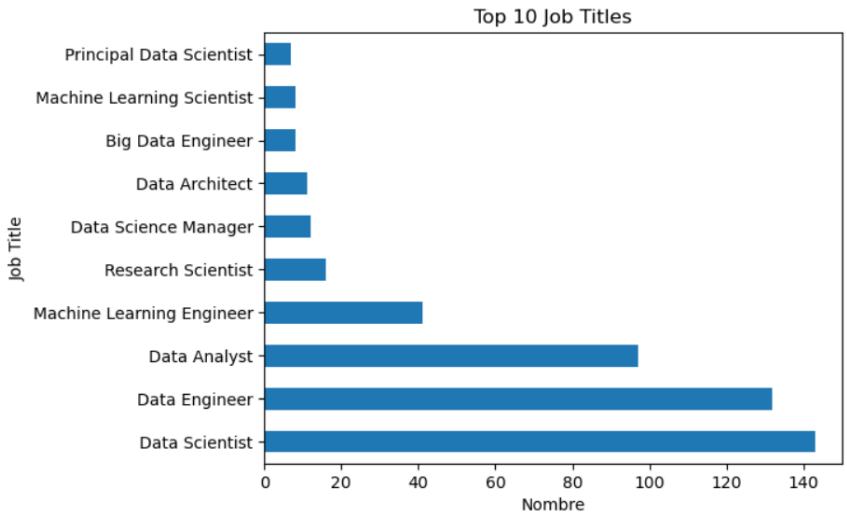



Le diagramme de Pareto montre que la catégorie Remote Ratio = 100 est largement dominante, avec plus de 60 % des observations, ce qui indique que la majorité des cas correspondent à un travail totalement à distance. La courbe cumulée confirme que cette seule catégorie contribue de manière significative au total global. En ajoutant la catégorie Remote Ratio = 0, le pourcentage cumulé atteint environ 85 %, ce qui signifie que ces deux catégories expliquent l'essentiel du phénomène étudié. La catégorie Remote Ratio = 50 présente une fréquence nettement plus faible et a donc un impact marginal sur le résultat global. Ainsi, selon le principe de Pareto, l'analyse et la prise de décision doivent se concentrer principalement sur les catégories les plus contributives, en particulier le Remote Ratio = 100.

La majorité des employés travaillent 100 % à distance (=63 %). Le travail sur site (=21 %) et hybride (=16 %) sont moins représentés. Globalement, le secteur est fortement orienté vers le télétravail.

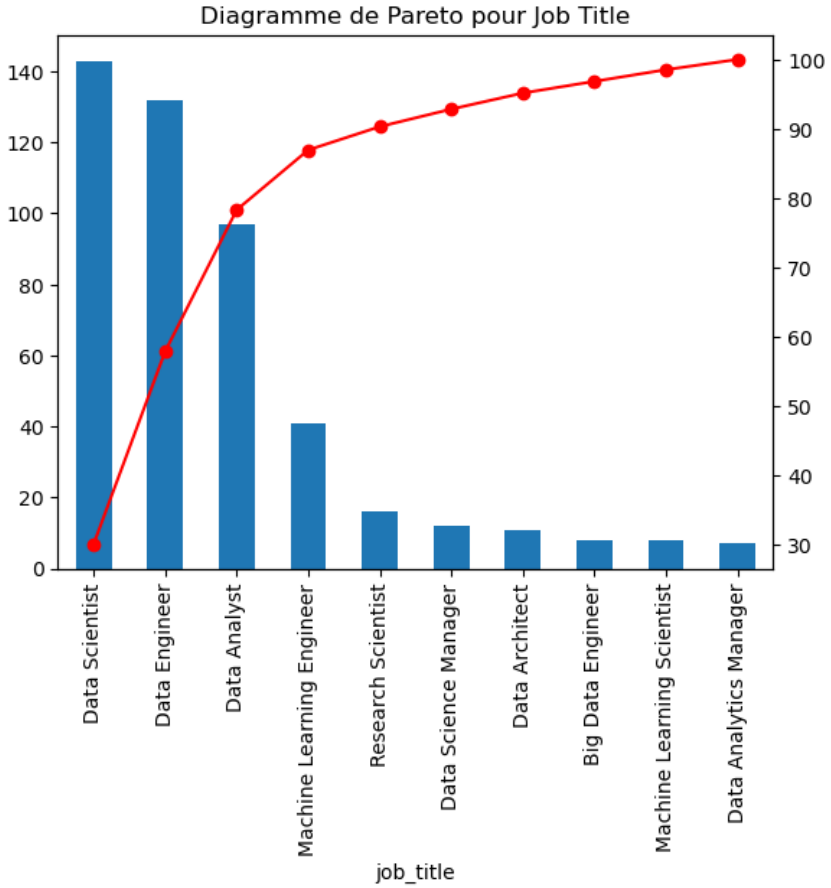
## 2.2 Variables qualitatives

### 2.2.1 Nom de spécialité




il existe dans je jeu de données 50 différent postes mais on affiche les 10 plus fréquents

Le graphique montre les 10 postes les plus fréquents dans le dataset. Les postes Data Scientist, Data Engineer et Data Analyst sont les plus représentés. Les autres postes apparaissent avec des effectifs nettement plus faibles.



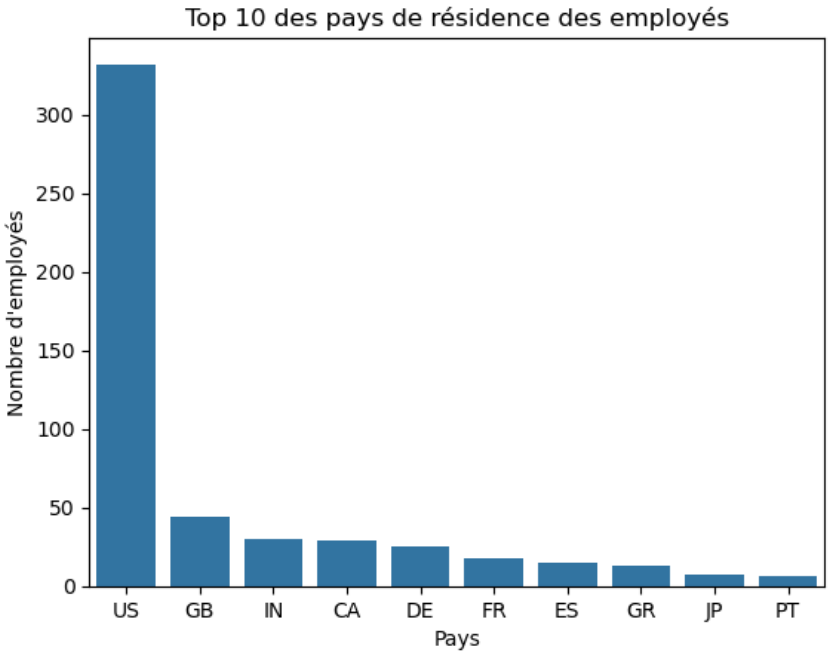

Le diagramme de Pareto montre que quelques postes seulement concentrent la majorité des observations. La courbe cumulée augmente rapidement et atteint un pourcentage élevé

après les trois premiers postes. Cela indique que la distribution des intitulés de poste est dominée par un petit nombre de catégories.

Les postes Data Scientist, Data Engineer et Data Analyst dominent largement le dataset.

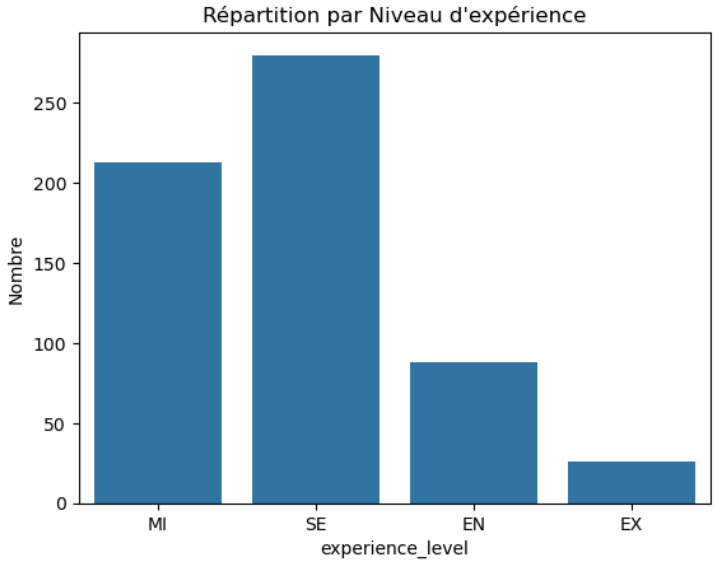
La majorité des observations est concentrée dans quelques métiers seulement.

### 2.2.2 Pays de résidence

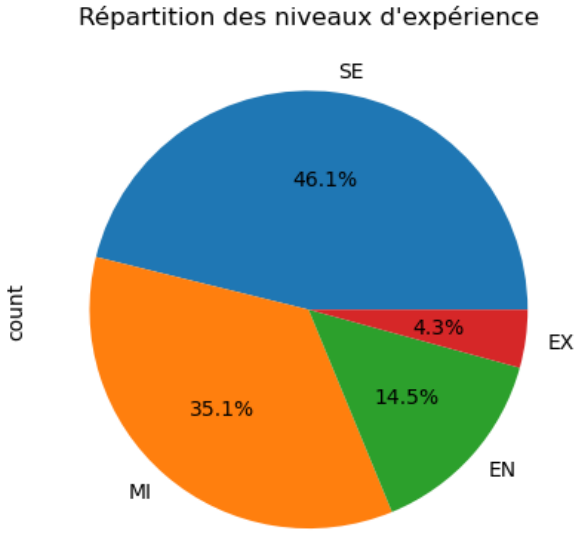



Le diagramme en barres montre que les États-Unis (US) dominent très largement le jeu de données, suivis par le Royaume-Uni (GB) et les Pays-Bas (NL). On observe une forte concentration géographique : la majorité des employés résident dans des pays occidentaux, avec une présence notable de pays européens (France, Allemagne, Espagne, Grèce, Portugal). Cela indique que le jeu de données reflète principalement le marché de l'emploi data aux États-Unis et en Europe de l'Ouest.

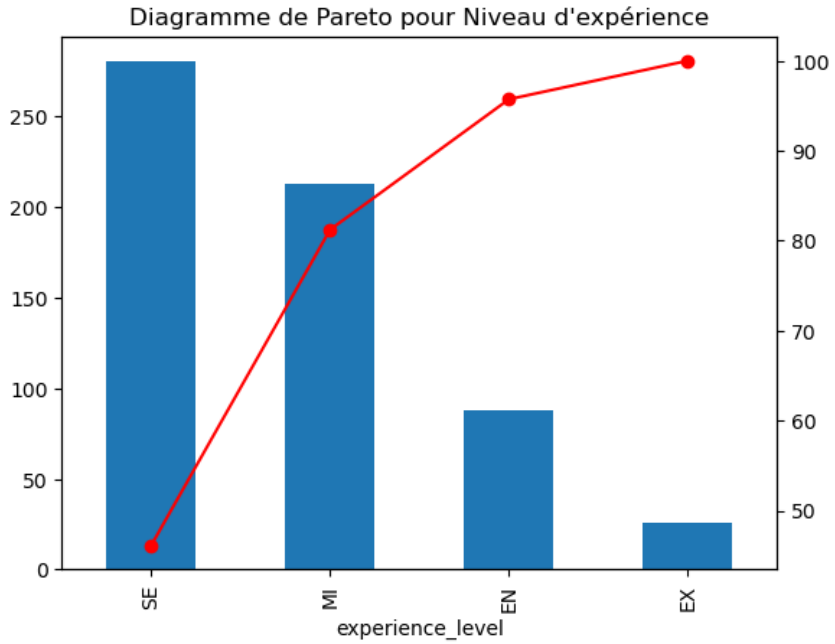
## Niveau d'expérience




Le graphique montre que le niveau SE (Senior) est le plus représenté, suivi du niveau MI (Mid-level). Les niveaux EN (Entry) et surtout EX (Executive) sont moins fréquents.




La majorité des professionnels du dataset sont des profils expérimentés, avec 46,1 % de Seniors et 35,1 % de Mid-level. Les débutants représentent seulement 14,5 %, tandis que les Executive ne constituent que 4,3 %. Cela montre que le secteur est dominé par des profils expérimentés, ce qui indique un marché mature où l'expérience joue un rôle important.




Le diagramme de Pareto confirme que les niveaux SE et MI concentrent la majorité des observations. La courbe cumulée augmente rapidement après ces deux catégories, montrant que la distribution est dominée par ces niveaux d'expérience.

La variable experience_level montre que la majorité des professionnels sont de niveau Senior (=46%), suivis des Mid-level (=35%).

Les niveaux Entry (=5%) et surtout Executive (=4%) sont minoritaires.

Globalement, le dataset est dominé par des profils expérimentés.

## 2.3 Décisions

- L'analyse des salaires montre une forte variation selon l'expérience. Les entreprises doivent proposer des salaires compétitifs pour rester attractives.
- Nous avons observé que le télétravail domine largement. Il est donc stratégique pour l'entreprise d'investir davantage dans les infrastructures numériques, les outils collaboratifs et la gestion à distance.Cela permettrait d'améliorer la productivité et d'attirer des talents internationaux.
- La concentration des effectifs sur Data Scientist, Data Engineer et Data Analyst montre que le marché est structuré autour de ces métiers centraux.
  Les entreprises doivent donc aligner leur stratégie RH sur ces profils à forte demande, en proposant des parcours attractifs et compétitifs.
  De leur côté, les candidats ont intérêt à développer des compétences dans ces spécialités dominantes pour maximiser leur employabilité et leur valeur sur le marché.
- Les entreprises doivent continuer à valoriser les profils seniors, tout en investissant dans la formation et le recrutement de débutants pour assurer un équilibre et préparer les futurs talents.
- La concentration des employés aux États-Unis et en Europe indique que ces régions représentent les marchés les plus dynamiques.

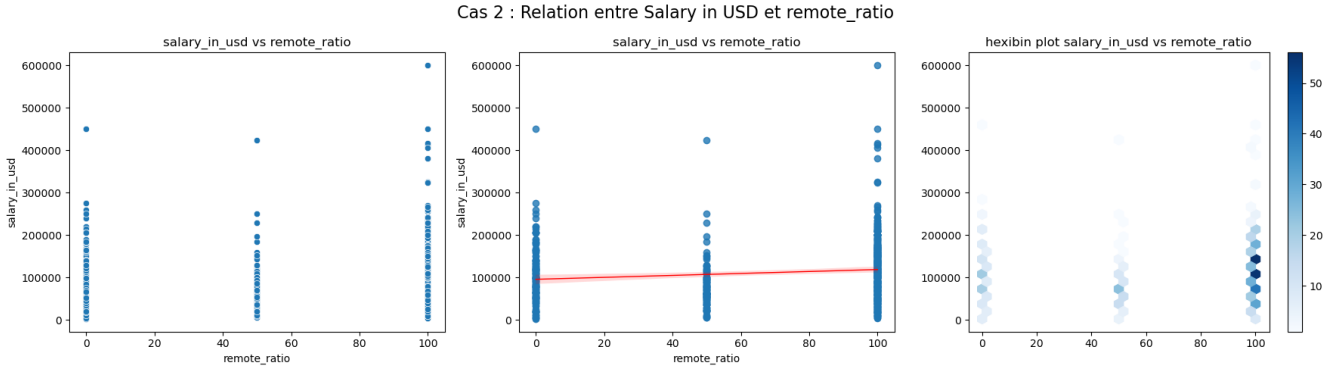
# Chapitre 3

# Visualisation Bivariée

La visualisation bivariée permet d'étudier la relation entre deux variables afin d'identifier d'éventuelles corrélations ou dépendances. Elle aide à comprendre comment une variable influence une autre, que ce soit entre variables quantitatives, qualitatives ou mixtes. Pour cela, nous utilisons des graphiques adaptés tels que les scatter plots, boxplots et graphiques en barres afin de mettre en évidence les relations significatives entre les variables.

## 3.1 Quantitative – Quantitative

### 3.1.1 Cas 1 : salary_in_usd vs remote_ratio

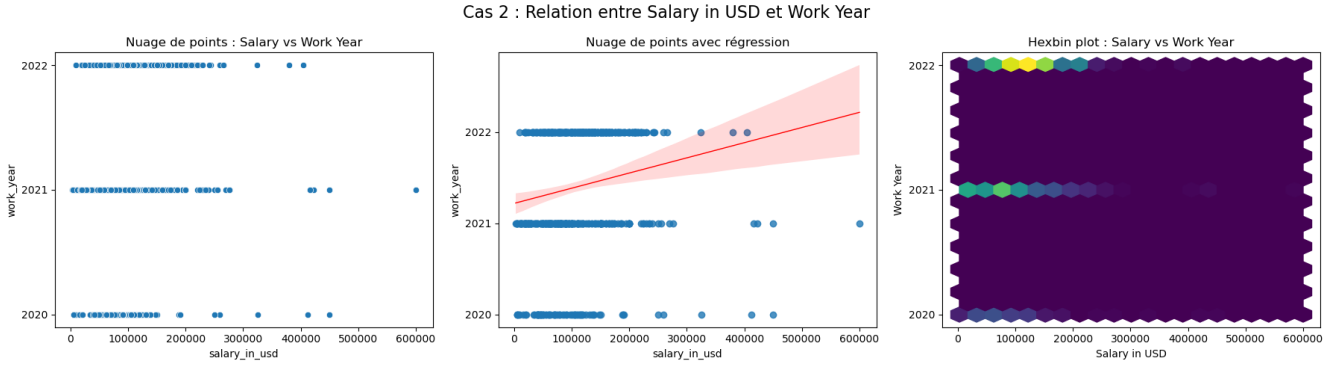



Le nuage de points montre que les salaires varient fortement quel que soit le niveau de travail à distance. On ne remarque pas de relation claire entre le pourcentage de travail remote et le salaire.

La ligne de régression indique une relation très faible entre le remote ratio et le salaire. Cela suggère que le niveau de travail à distance n'a pas d'impact significatif sur le salaire des employés dans ce dataset.

Le hexbin plot met en évidence les zones où les observations sont les plus concentrées. La majorité des employés ont un salaire situé dans une plage moyenne, indépendamment du niveau de travail à distance.

### 3.1.2 Cas 2 : salary_in_usd vs work_year



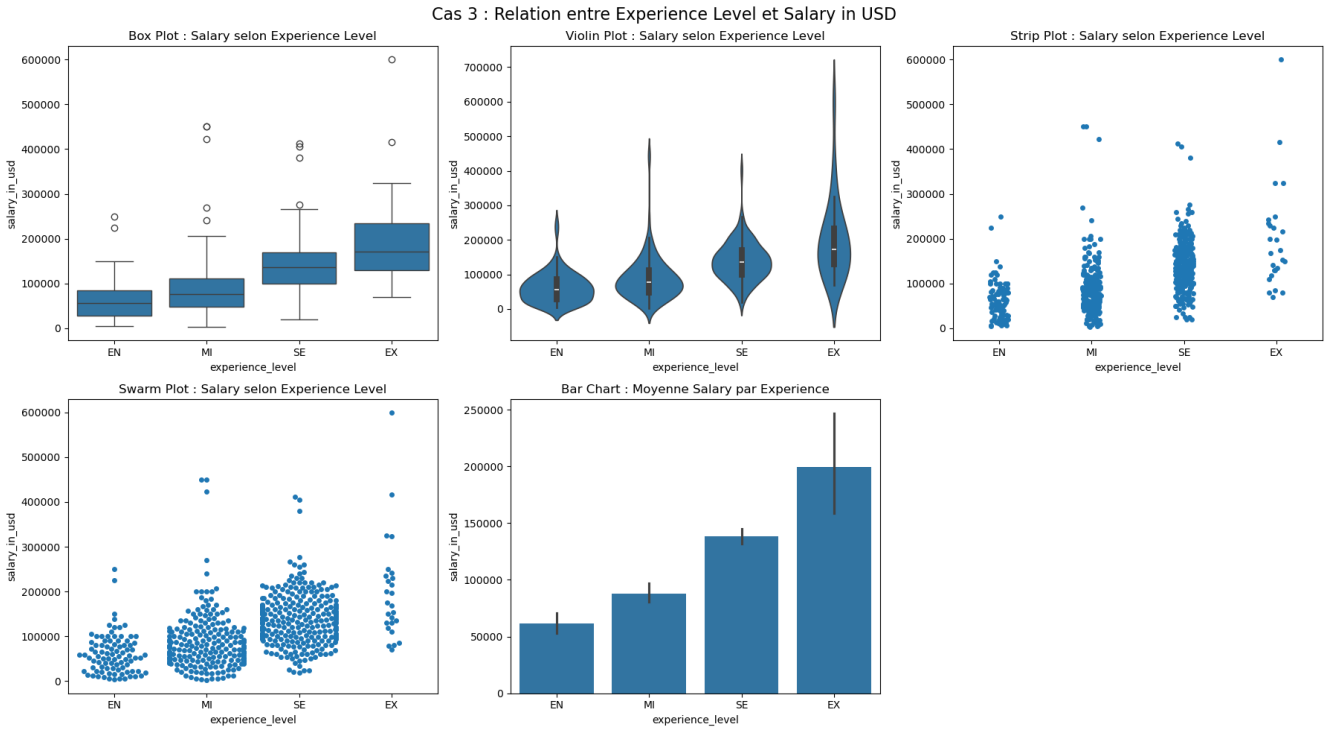

Le nuage de points montre que les salaires varient fortement d'une année à l'autre. On observe également une tendance à l'augmentation des salaires dans les années les plus récentes.

La ligne de régression suggère une tendance à la hausse des salaires au fil des années, ce qui peut indiquer une augmentation de la demande pour les métiers liés à la data.

Le hexbin plot met en évidence que la majorité des salaires se situe dans une plage moyenne, avec une tendance à des salaires plus élevés dans les années récentes

## 3.2 Qualitative – Quantitative

### 3.2.1 Cas 3 : experience_level vs salary_in_usd




Le box plot montre que le salaire augmente généralement avec le niveau d'expérience. Les employés ayant plus d'expérience ont tendance à recevoir des salaires plus élevés.

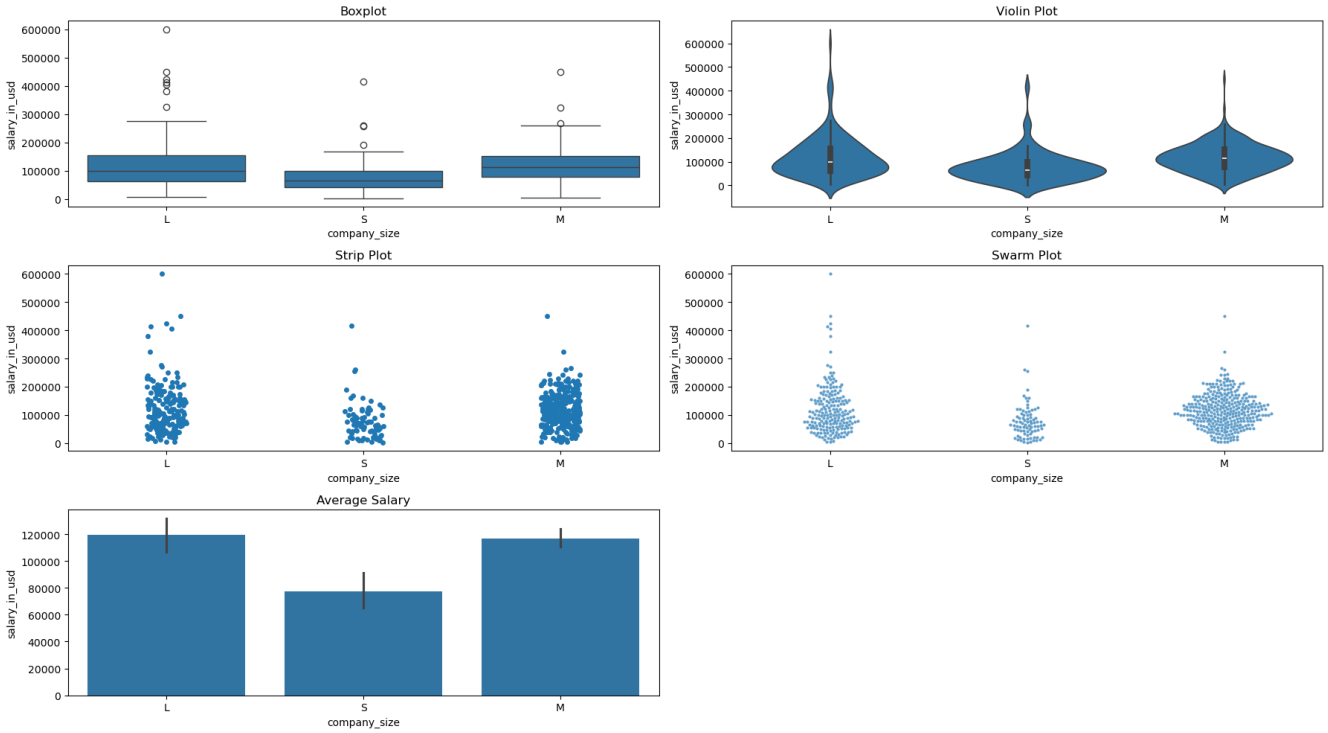
Le violin plot montre la distribution des salaires pour chaque niveau d'expérience. On observe que les niveaux d'expérience élevés présentent une plus grande dispersion et des salaires généralement plus élevés.

Le strip plot permet d'observer les valeurs individuelles des salaires. On remarque que les salaires les plus élevés sont principalement associés aux niveaux d'expérience supérieurs.

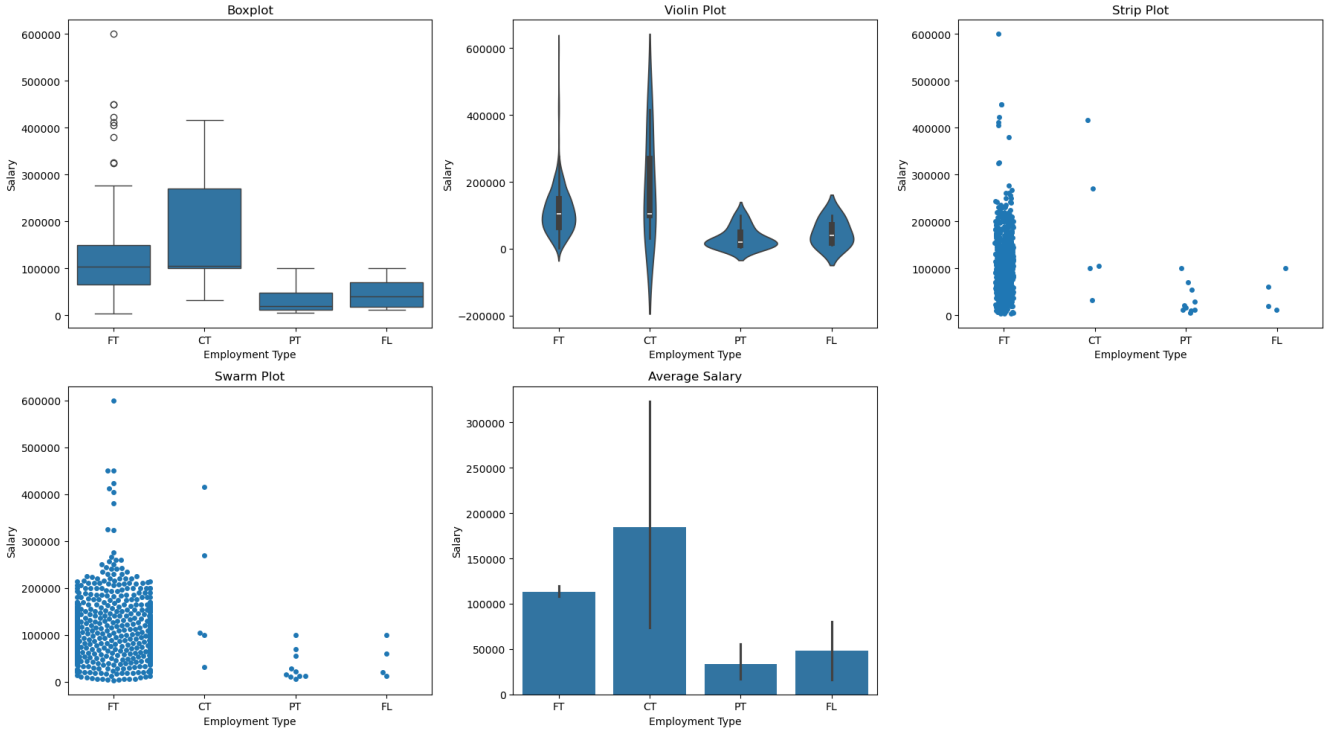
Le swarm plot confirme que les salaires augmentent avec l'expérience et montre clairement la répartition des observations dans chaque catégorie.

Le bar chart montre que la moyenne des salaires augmente avec le niveau d'expérience, ce qui indique une relation positive entre expérience et rémunération.

### 3.2.2 Cas 4 : company_size vs salary_in_usd



### 3.2.3 Cas 5 : employment_type vs salary_in_usd




Le box plot montre la distribution des salaires pour chaque type de contrat. On observe que les employés à temps plein (FT) ont généralement des salaires plus élevés et une dispersion plus large. Cela signifie que les salaires varient beaucoup dans cette catégorie. Les contrats part-time (PT) et contract (CT) ont des salaires plus faibles et une distribution plus concentrée.

Le violin plot permet d'observer la forme de la distribution des salaires. On remarque que la distribution est plus large pour les emplois à temps plein, ce qui indique une plus grande diversité de niveaux de salaire. Les autres types de contrats présentent une distribution plus étroite, ce qui signifie que leurs salaires sont généralement plus homogènes et plus faibles.

Le strip plot montre chaque observation individuelle de salaire. On constate que la majorité des salaires élevés correspond aux contrats à temps plein, tandis que les contrats part-time et contract ont moins d'observations avec des salaires élevés.

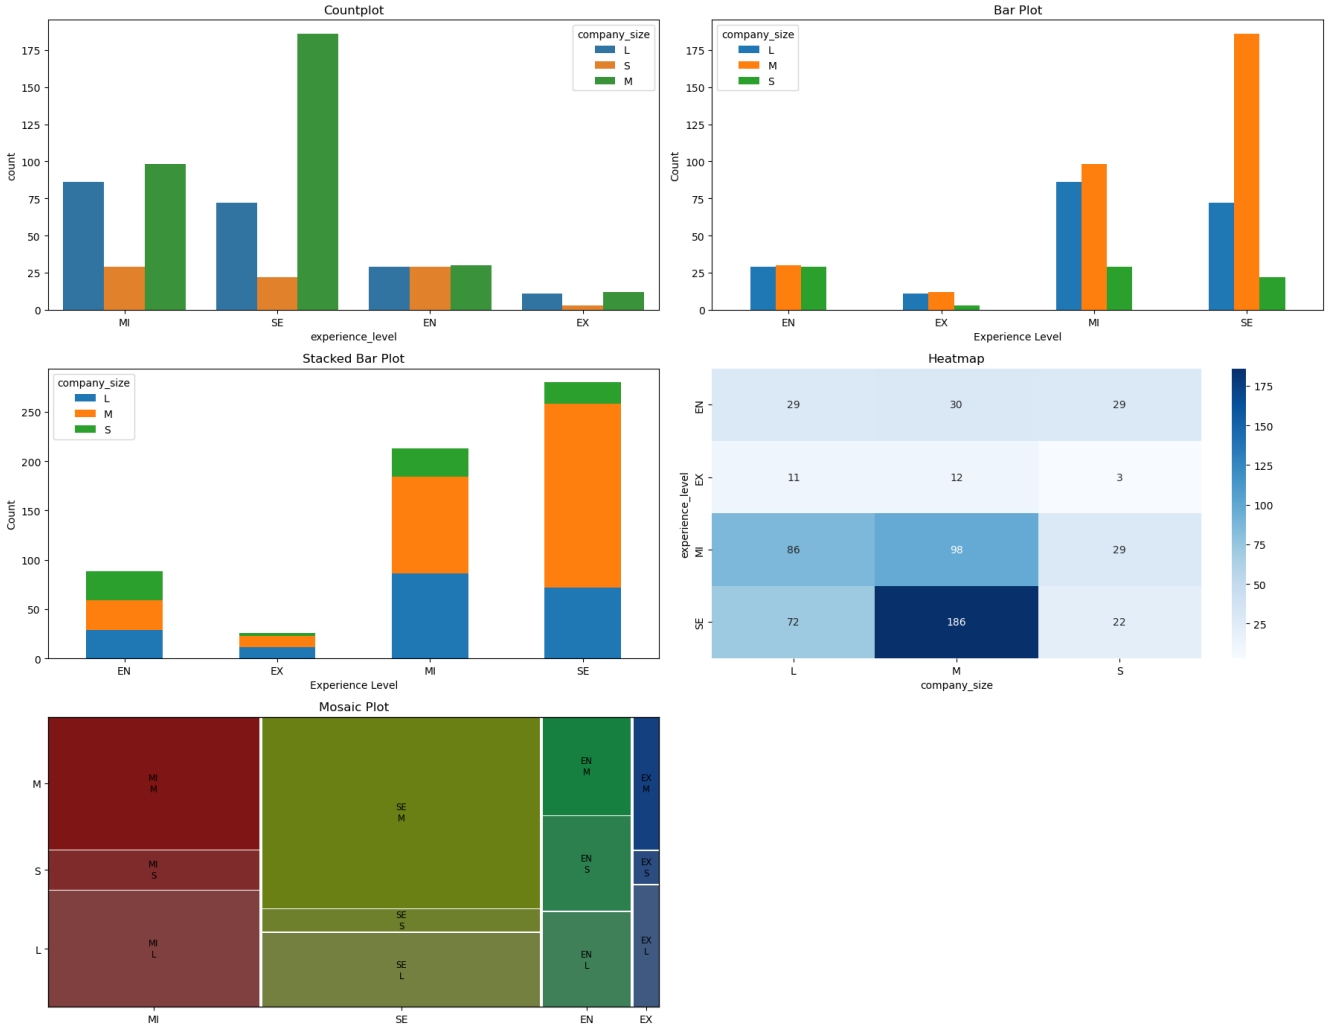
Le swarm plot permet de visualiser la répartition des salaires sans chevauchement des points. On observe que les points représentant les emplois à temps plein sont plus nombreux et souvent situés à des niveaux de salaire plus élevés.

Le bar chart montre la moyenne des salaires pour chaque type de contrat. Il indique que les employés à temps plein ont la moyenne de salaire la plus élevée, tandis que les autres types de contrats ont des salaires moyens plus faibles.

L'analyse des différents diagrammes montre que le type de contrat influence le niveau de salaire. Les emplois à temps plein offrent généralement les salaires les plus élevés et la plus grande diversité de rémunération, tandis que les contrats part-time ou contract ont des salaires plus faibles et plus stables.

## 3.3 Qualitative – Qualitative

### 3.3.1 Cas 6 : experience_level vs company_size




Le count plot croisé montre le nombre d'employés pour chaque niveau d'expérience dans les différentes tailles d'entreprises. On observe généralement que les entreprises moyennes (M) et grandes (L) recrutent davantage d'employés Senior (SE) et Mid-level (MI). Les Entry-level (EN) sont moins nombreux, surtout dans les grandes entreprises.

Le diagramme en barres groupées permet de comparer directement les niveaux d'expérience dans chaque taille d'entreprise. On remarque que certaines tailles d'entreprises ont une concentration plus élevée de certains niveaux d'expérience, notamment les Senior dans les grandes entreprises.

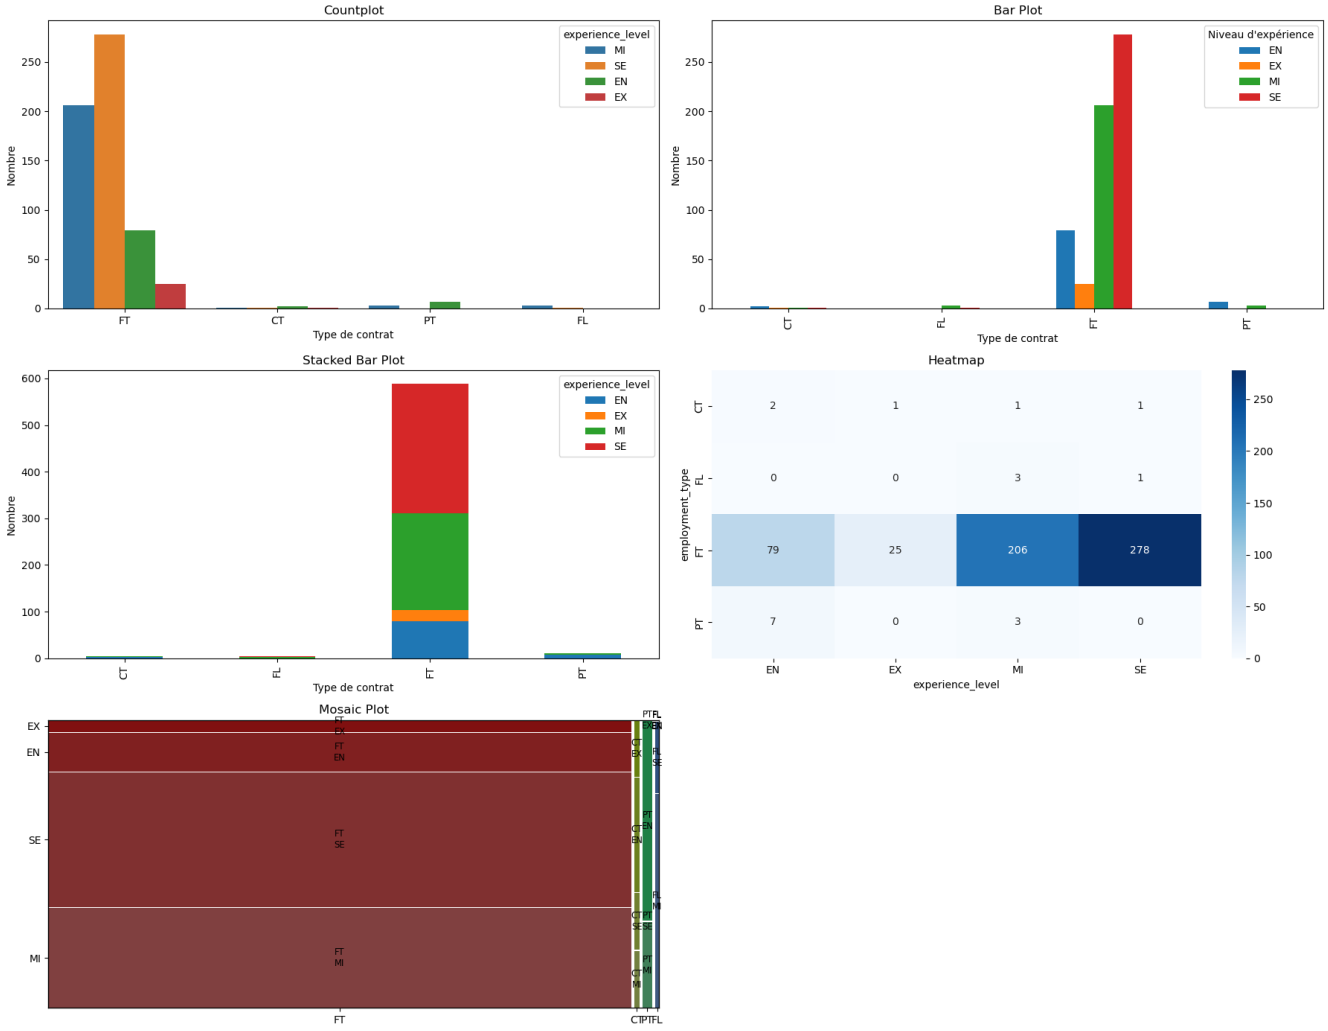
Le diagramme empilé montre la proportion des différents niveaux d'expérience dans chaque taille d'entreprise. On observe que les grandes entreprises ont une proportion importante de profils Senior et Executive, tandis que les entreprises plus petites peuvent avoir une proportion plus variée.

La heatmap met en évidence les combinaisons les plus fréquentes grâce aux couleurs. Les cellules les plus foncées indiquent les combinaisons où il y a le plus d'employés, par exemple Senior dans les entreprises moyennes ou grandes.

Le mosaic plot montre la relation entre les deux variables en représentant la proportion de chaque combinaison par la surface des rectangles. Les rectangles les plus grands corres-

pondent aux combinaisons les plus fréquentes, ce qui confirme que les profils expérimentés sont plus présents dans les entreprises moyennes et grandes.

### 3.3.2 Cas 7 : employment_type vs experience_level




Le graphique en count plot croisé montre la distribution des niveaux d'expérience selon le type de contrat. On observe que les contrats Full-Time (FT) représentent la majorité des emplois dans le dataset. Les profils Mid-Level (MI) et Senior (SE) sont les plus fréquents dans ces contrats, tandis que les profils Entry-Level (EN) apparaissent moins souvent.

Le diagramme en barres groupées permet de comparer les niveaux d'expérience pour chaque type de contrat. On remarque que les contrats Full-Time contiennent la plus grande proportion de professionnels, notamment des profils Mid-Level et Senior. Les autres types de contrats comme Part-Time ou Contract sont moins représentés dans le dataset.

Le diagramme en barres empilées permet d'observer la proportion des différents niveaux d'expérience au sein de chaque type de contrat. Les contrats Full-Time présentent une diversité de niveaux d'expérience, mais les profils Mid-Level et Senior restent dominants. Les contrats temporaires ou partiels montrent une proportion plus faible d'employés.

La heatmap du tableau de contingence met en évidence les combinaisons les plus fréquentes entre type de contrat et niveau d'expérience. Les couleurs plus foncées indiquent

un nombre plus élevé d'observations. On constate que certaines combinaisons comme Full-Time avec Mid-Level ou Senior sont particulièrement fréquentes.

Le Mosaic Plot représente visuellement la proportion de chaque combinaison entre type de contrat et niveau d'expérience. La taille des rectangles indique la fréquence relative de chaque catégorie. Les rectangles les plus grands correspondent aux combinaisons les plus présentes dans le dataset.

## 3.4 Décisions

- Les entreprises doivent augmenter les salaires pour attirer les talents
- Les organisations doivent investir dans la formation
- Il faut investir dans l'expérience et le développement des compétences.
- Les grandes entreprises attirent des profils expérimentés grâce à des salaires élevés
- Les entreprises moyennes ciblent des profils intermédiaires avec un bon équilibre entre rémunération et stabilité
- Les petites entreprises privilégient les profils juniors en valorisant l'apprentissage.
- Le marché favorise clairement l'expérience : les juniors doivent se former en PME avant de viser les grandes entreprises, tandis que les seniors sont la ressource la plus stratégique pour toutes les structures.

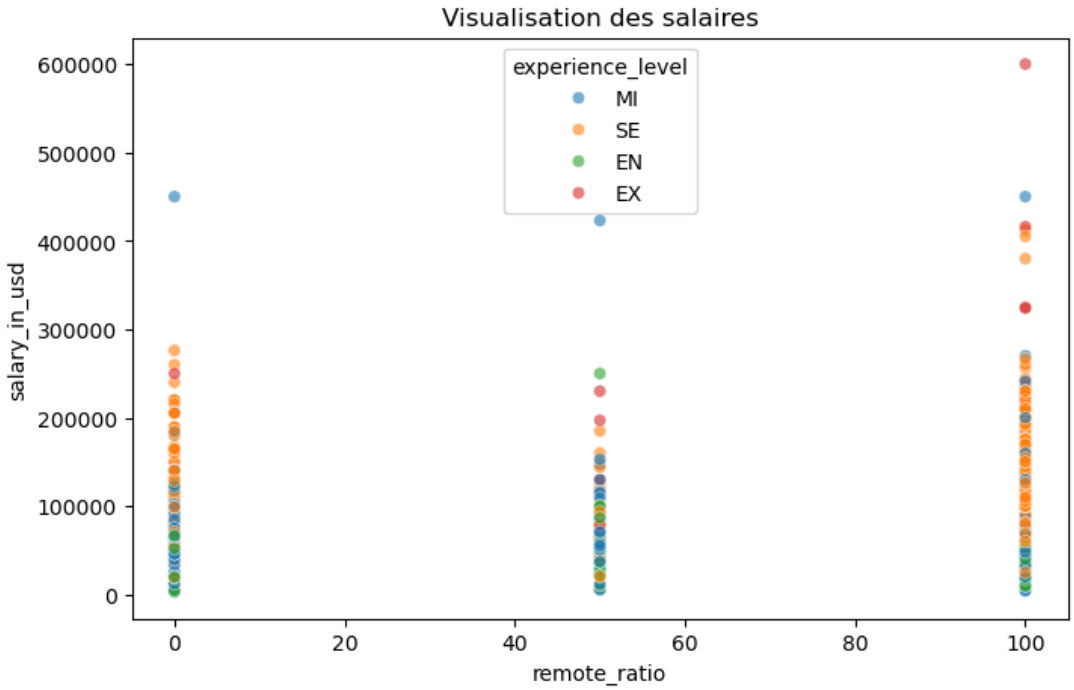
# Chapitre 4

# Visualisation Multivariée

La visualisation multivariée permet d'analyser simultanément plusieurs variables afin de comprendre des relations plus complexes dans les données. Elle offre une vision globale du dataset en mettant en évidence les interactions entre différents facteurs influençant les salaires. Dans cette partie, nous utilisons des techniques avancées telles que le pairplot, la heatmap, les coordonnées parallèles et l'ACP pour explorer les dépendances, comparer les groupes et simplifier la structure des données.

## 4.1 Visualiser les relations entre plusieurs variables

### 4.1.1 Scatter plot




— Le graphique montre la relation entre le niveau de travail à distance (0 %, 50 %, 100 %) et le salaire en USD.
— Les salaires les plus élevés sont majoritairement observés dans les postes 100 % remote.
— Les postes hybrides (50 %) présentent des salaires plus concentrés et généralement intermédiaires.

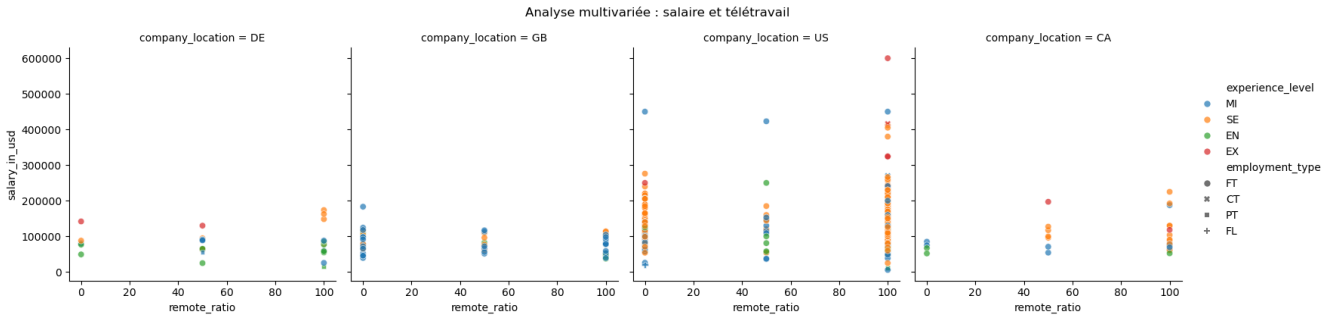
— Les emplois en présentiel (0 %) montrent une grande dispersion des salaires, mais moins de valeurs très élevées.
— Les niveaux d'expérience élevés (Senior et Executive) sont associés aux salaires les plus importants, tandis que les niveaux débutants ont des salaires plus faibles.

Le travail à distance complet et l'expérience professionnelle élevée sont des facteurs liés à des salaires plus élevés.



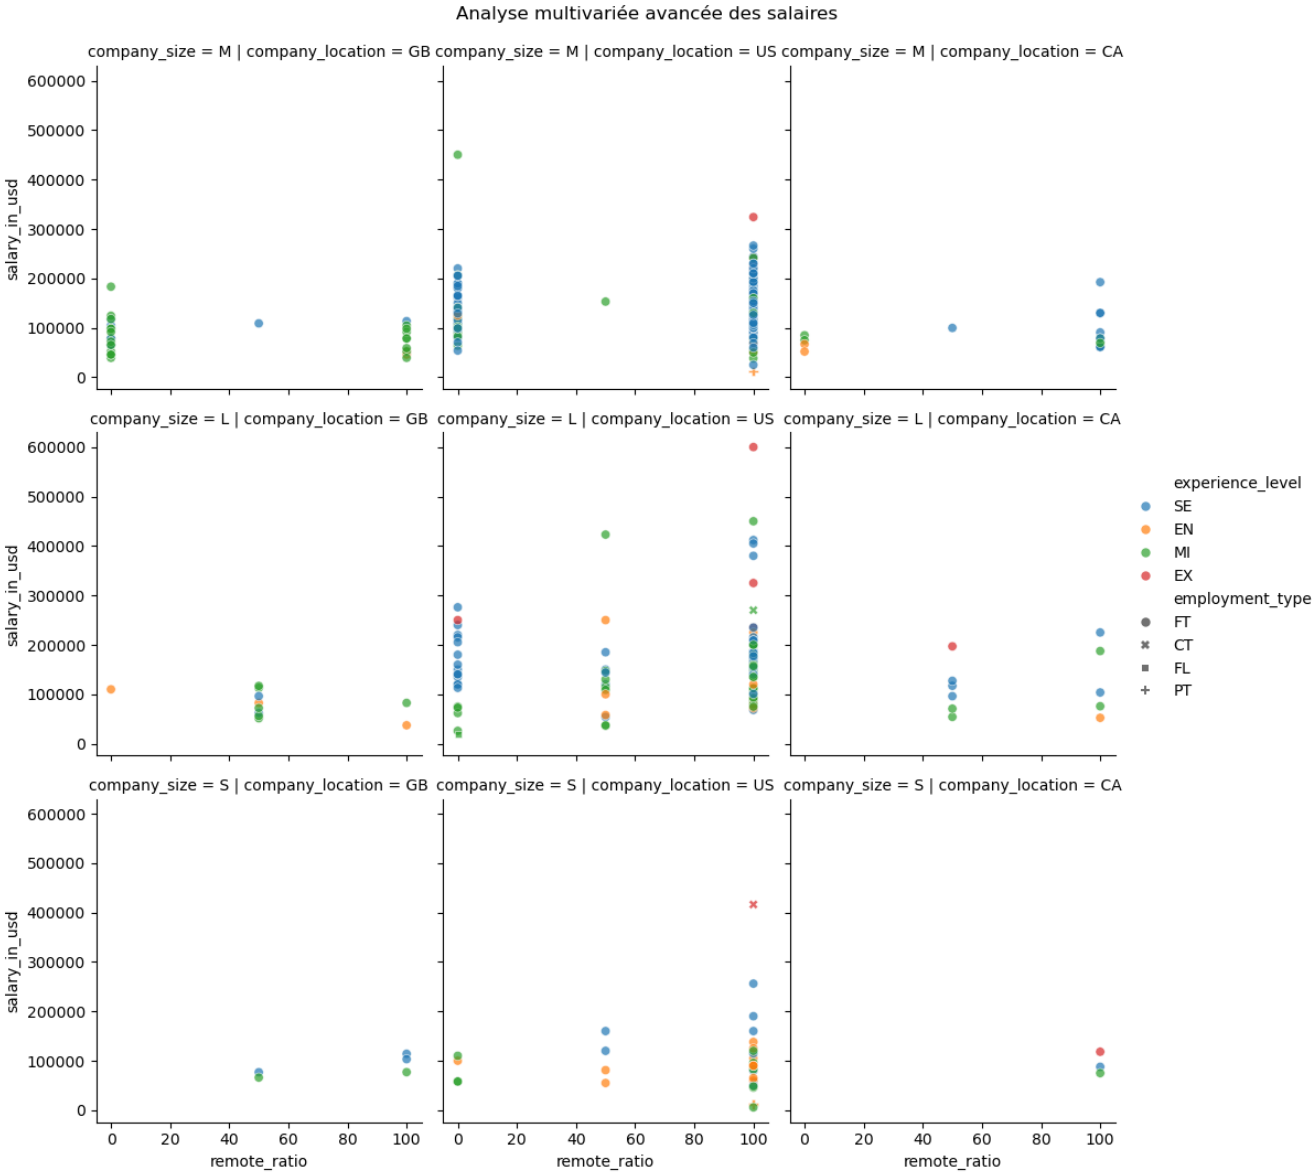

— Le graphique montre la relation entre le niveau de travail à distance (remote_ratio) et le salaire en USD.
— Les salaires les plus élevés apparaissent surtout dans les postes 100 % remote.
— Les postes hybrides (50 %) présentent des salaires plus concentrés et généralement intermédiaires.
— La majorité des points correspond à des emplois à temps plein (FT).
— Les niveaux d'expérience élevés (Senior et Executive) sont associés aux salaires les plus importants.

Globalement, les postes totalement à distance semblent offrir plus d'opportunités de salaires élevés, surtout pour les profils expérimentés et en emploi à temps plein.



— Le graphique montre la relation entre le salaire, le remote ratio et la localisation de l'entreprise (DE, GB, US, CA).
— Les salaires les plus élevés sont principalement observés aux États-Unis, surtout pour les postes 100 % remote.
— Les pays comme l'Allemagne (DE), le Royaume-Uni (GB) et le Canada (CA) présentent des salaires plus modérés et moins dispersés.
— Le travail totalement à distance (100 %) est souvent associé à des salaires plus élevés dans presque tous les pays.
— Les niveaux d'expérience élevés (Senior et Executive) correspondent aux salaires les plus importants.
— La majorité des postes bien rémunérés sont des emplois à temps plein (FT).

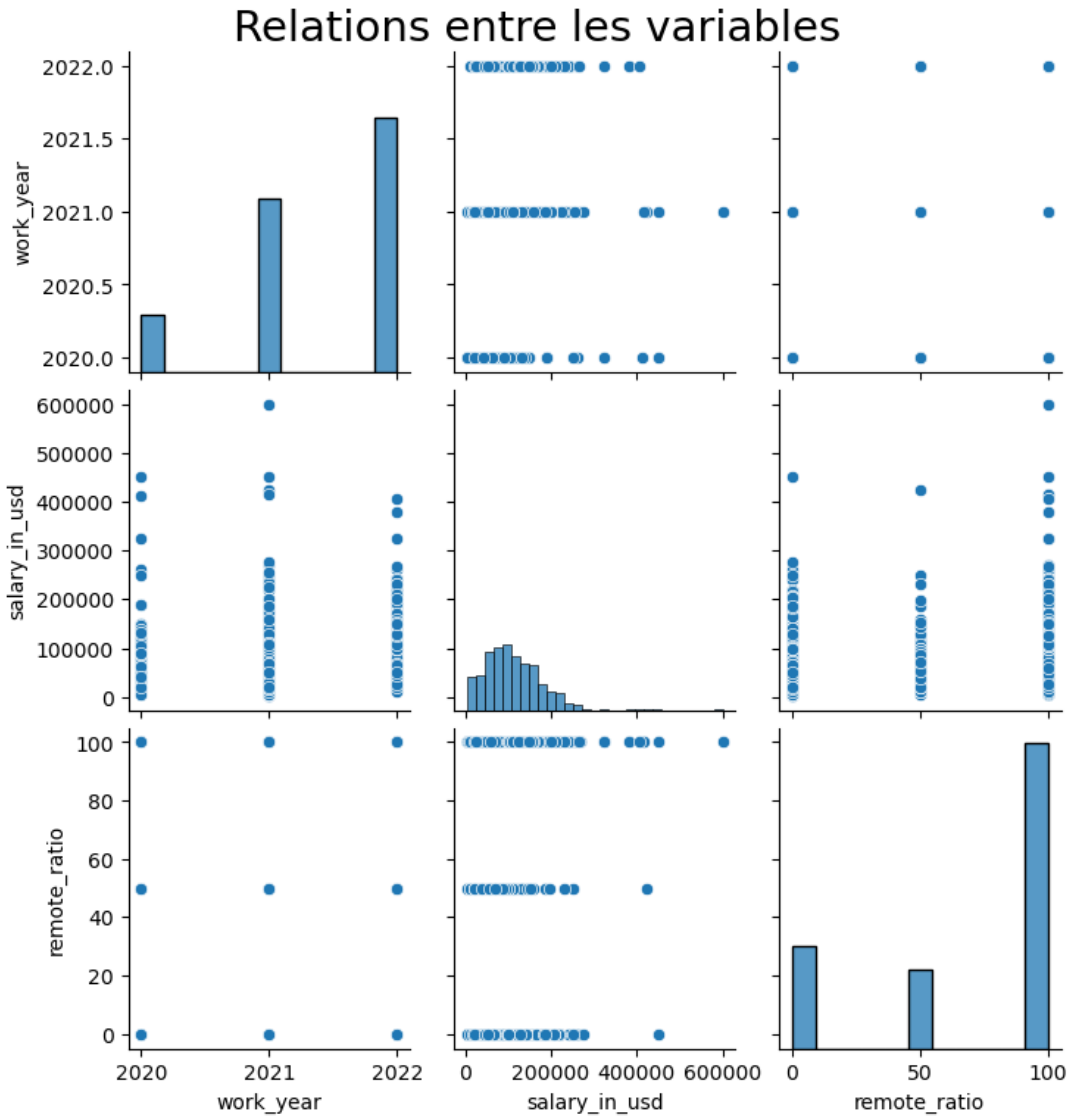
Le salaire dépend fortement de la localisation de l'entreprise, mais aussi du niveau d'expérience et du travail à distance, avec un avantage clair pour les États-Unis et les postes remote.




— Les salaires les plus élevés sont observés principalement aux États-Unis, surtout dans les entreprises moyennes (M) et grandes (L).
— Les postes 100 % remote présentent plusieurs salaires élevés, ce qui montre que le travail à distance peut offrir de meilleures opportunités salariales.

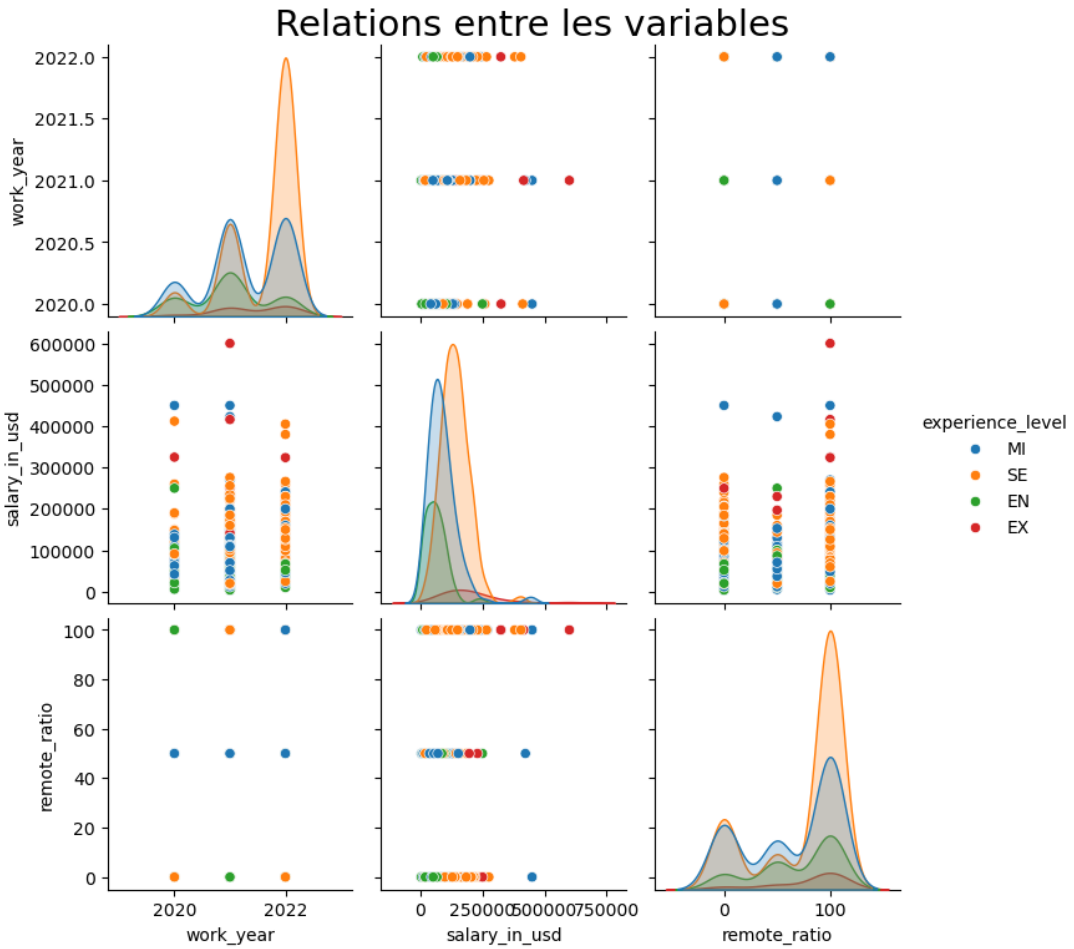
— Les niveaux d'expérience élevés (Senior et Executive) sont associés aux salaires les plus importants, tandis que les niveaux Entry et Mid ont des salaires plus faibles.
— La majorité des salaires élevés concerne des emplois à temps plein (FT).
— Les petites entreprises (S) et certaines localisations comme GB et CA montrent généralement des salaires plus modérés.

### 4.1.2 Pairplot



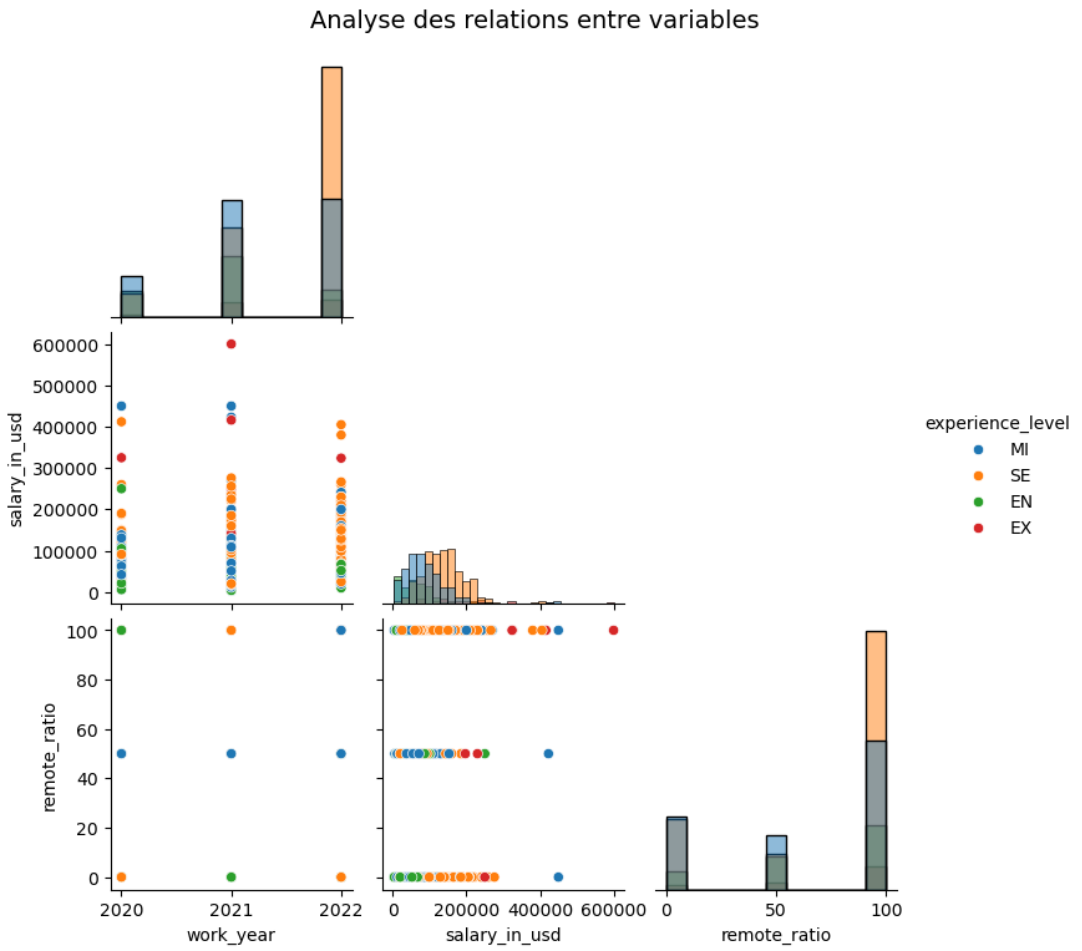

— Le graphique montre les relations entre l'année (work_year), le salaire en USD et le niveau de travail à distance (remote ratio).
— On observe une augmentation globale des salaires entre 2020 et 2022, avec plus de valeurs élevées en 2022.
— Les salaires sont très dispersés, allant de faibles valeurs à plus de 600 000 USD, ce qui indique une forte variabilité.
— Le remote ratio 100 % est le plus fréquent, ce qui montre que le travail à distance est devenu dominant.
— Les salaires élevés apparaissent dans tous les niveaux de remote, mais sont plus visibles avec le 100 % remote.

Les salaires ont tendance à augmenter avec le temps, et le travail à distance est devenu majoritaire, avec une influence possible sur les salaires élevés.




— Ce graphique montre les relations entre le salaire (salary_in_usd), l'année (work_year) et le niveau de travail à distance (remote_ratio) selon le niveau d'expérience.
— On observe que les salaires augmentent avec le niveau d'expérience : les profils Executive (EX) et Senior (SE) ont les salaires les plus élevés.
— Les salaires sont très dispersés, mais les valeurs les plus élevées apparaissent surtout après 2021 et 2022.
— Le remote ratio (0 %, 50 %, 100 %) n'a pas une relation très forte directe avec le salaire, mais les postes 100 % remote montrent plusieurs salaires élevés.
— Les niveaux Entry (EN) ont des salaires plus faibles et moins dispersés.

Le niveau d'expérience est le facteur le plus déterminant du salaire, tandis que l'année et le travail à distance ont un effet secondaire mais visible.




— L'axe vertical (remote_ratio) prend principalement trois valeurs : 0 (présentiel), 50 (hybride) et 100 (full remote), ce qui explique les lignes horizontales de points.
— Sur la ligne 100 % remote, on observe plusieurs points avec des salaires très élevés, ce qui indique que les postes les mieux payés sont souvent entièrement à distance.
— La ligne 50 % (hybride) montre des salaires moins dispersés, concentrés dans une tranche moyenne.
— La ligne 0 % (présentiel) contient majoritairement des salaires plus faibles à intermédiaires, avec peu de valeurs extrêmes.
— Les couleurs indiquent que les points avec salaires élevés correspondent surtout aux niveaux Senior et Executive, alors que les niveaux Junior/Mid sont plus bas.

Les salaires les plus élevés se trouvent principalement dans les postes 100 % remote et occupés par des profils expérimentés, tandis que les postes hybrides ou en présentiel sont associés à des salaires plus modérés.

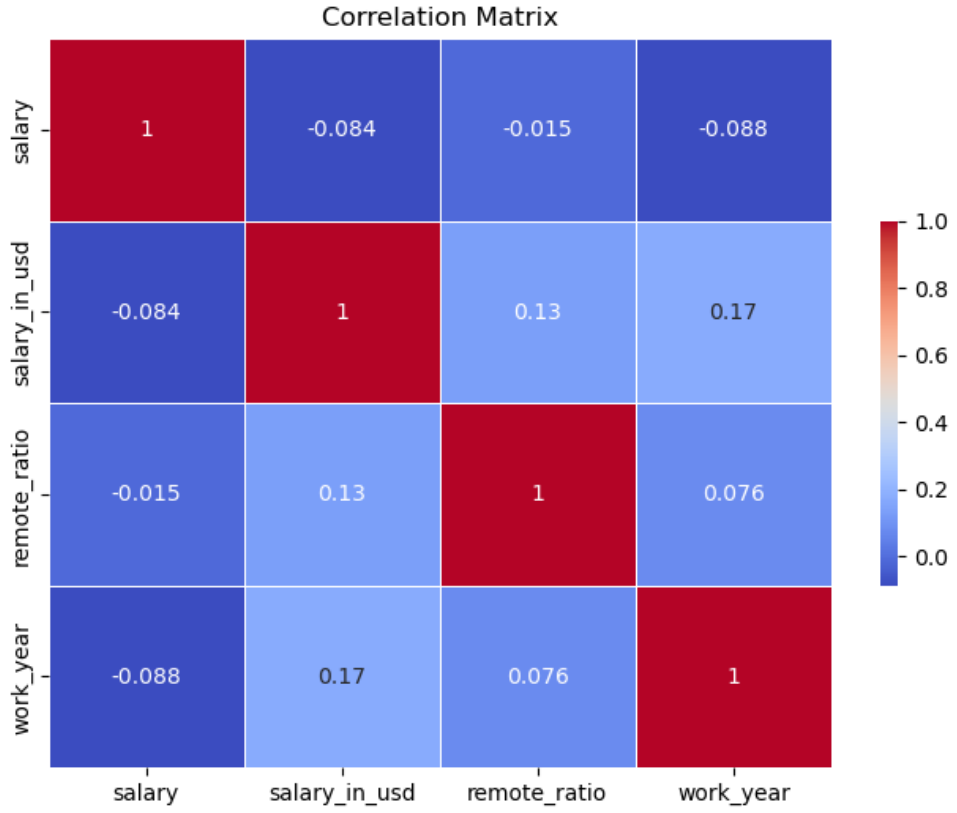
### 4.1.3 Décisions

Après cette analyse, on propose des décisions basées sur les facteurs qui influencent le plus le salaire : le remote, l'expérience, la taille de l'entreprise et la localisation.

— Prioriser les postes remote pour accéder à des salaires plus élevés.
— Cibler les entreprises de grande taille, plus compétitives salarialement.
— Valoriser l'expérience professionnelle pour atteindre les niveaux de salaire élevés.
— S'orienter vers les marchés internationaux offrant de meilleures rémunérations.
— Favoriser les contrats temps plein, dominants dans les hauts salaires.

## 4.2 Analyser les dépendances entre variables

### 4.2.1 Heatmap




**Corrélations négatives (bleu foncé)**

— salary vs salary_in_usd = -0.084

Corrélation faible et négative — paradoxal à première vue !
Explication : salary est en devise locale (EUR, GBP, JPY...). Un salaire très élevé en Yen japonais peut être faible en USD donc les deux colonnes ne mesurent pas la même chose.

— salary vs work_year = -0.088

Très faible corrélation négative donc la devise locale du salaire n'a quasiment aucun lien avec l'année.

— salary vs remote_ratio = -0.015

Corrélation quasi nulle alors le mode de travail n'influence pas le salaire en devise locale.

**Corrélations positives (rouge/bleu clair)**

— salary_in_usd vs work_year = 0.17

Corrélation faible mais positive donc les salaires en USD tendent à augmenter avec les années récentes (2020 → 2022). Le marché Data Science est en croissance.

— salary_in_usd vs remote_ratio = 0.13

Légèrement positive alors les postes full remote sont légèrement mieux rémunérés en USD.

— remote_ratio vs work_year = 0.076

Très faible donc le télétravail a légèrement augmenté avec les années (effet post-Covid).

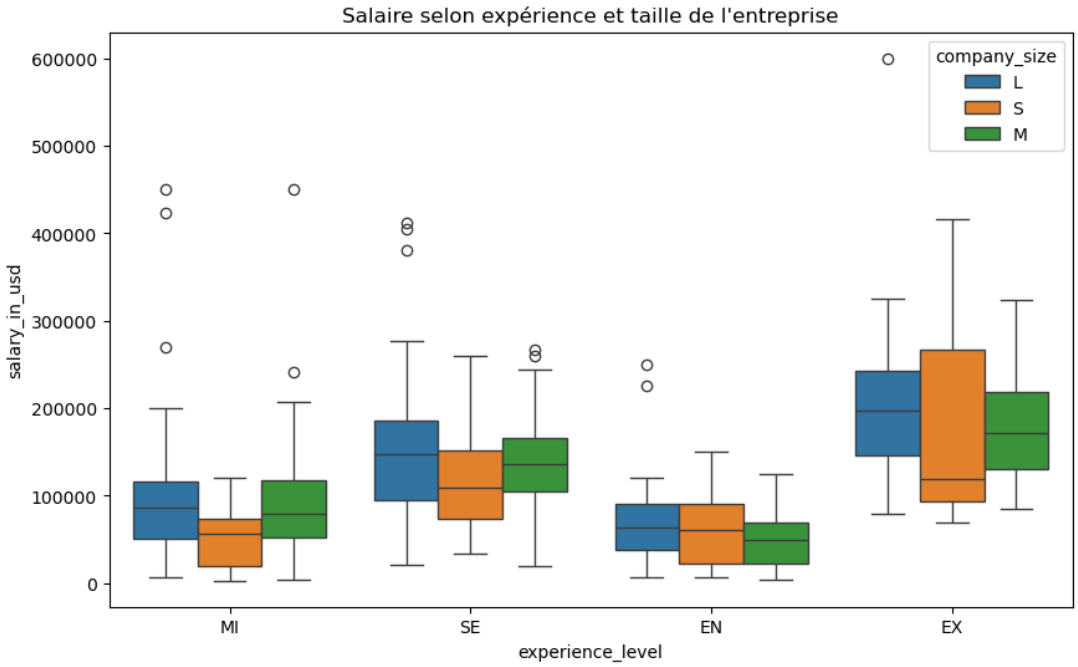
### 4.2.2 Décision

Les corrélations faibles ne sont pas un problème — elles révèlent que la rémunération est un phénomène multidimensionnel que ces 4 variables seules n'expliquent pas. Voici les orientations stratégiques clés :

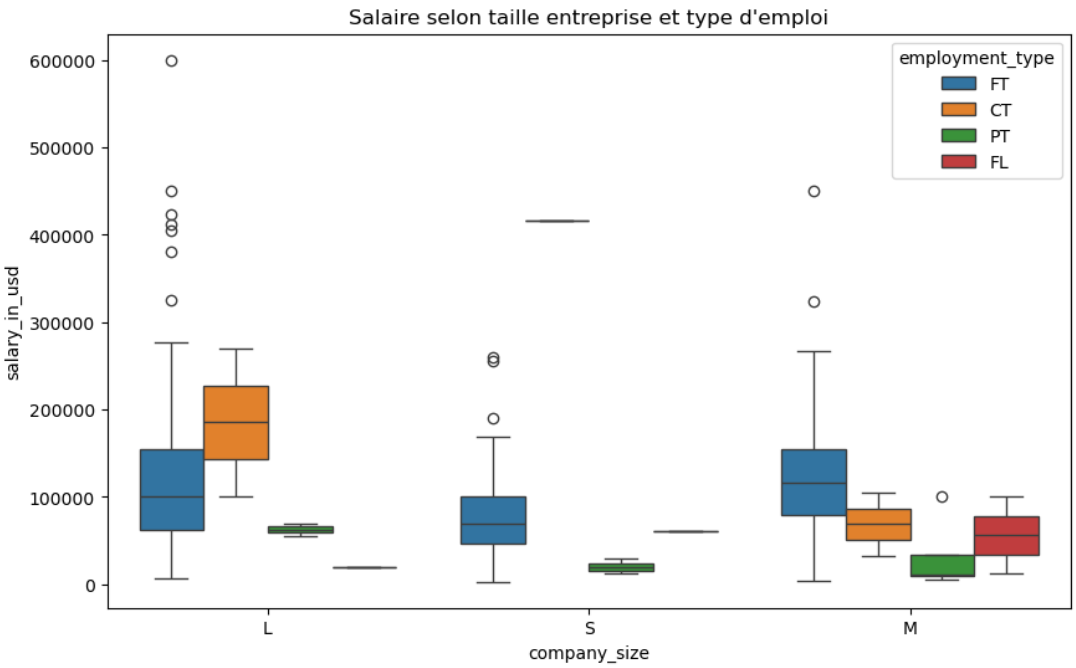
- Standardiser les comparaisons en USD — Le salaire brut local est un mauvais indicateur de compétitivité globale. Toute politique RH ou benchmark concurrentiel doit s'appuyer sur salary_in_usd.
- Réviser les grilles salariales annuellement — La légère hausse de salary_in_usd par année (+0.17) reflète l'inflation et la tension du marché tech. Une révision annuelle est nécessaire pour rester compétitif.
- Le remote est un levier de recrutement, pas de réduction de coûts — La corrélation positive entre remote et salary_in_usd suggère que les profils remote sont souvent plus qualifiés et mieux payés. Le remote attire les talents, il ne les dévalue pas.
- Explorer d'autres variables explicatives — Étant donné que ces 4 variables s'expliquent peu mutuellement, il est essentiel d'intégrer dans l'analyse des variables comme le niveau d'expérience (entry/senior), le domaine (ML, data eng., analytics), et la région géographique — qui seront bien plus corrélées au salaire.

## 4.3 Comparer des groupes

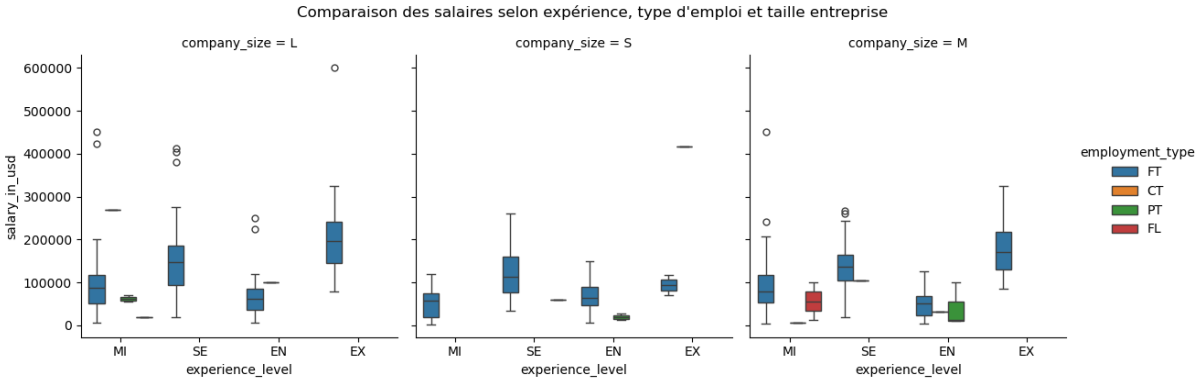
### 4.3.1 Boxplot




Le salaire augmente avec le niveau d'expérience. Pour chaque niveau, les grandes entreprises (L) offrent généralement les salaires les plus élevés, suivies des entreprises moyennes (M), puis des petites (S). La dispersion est plus importante pour les niveaux d'expérience élevés, notamment dans les grandes entreprises.

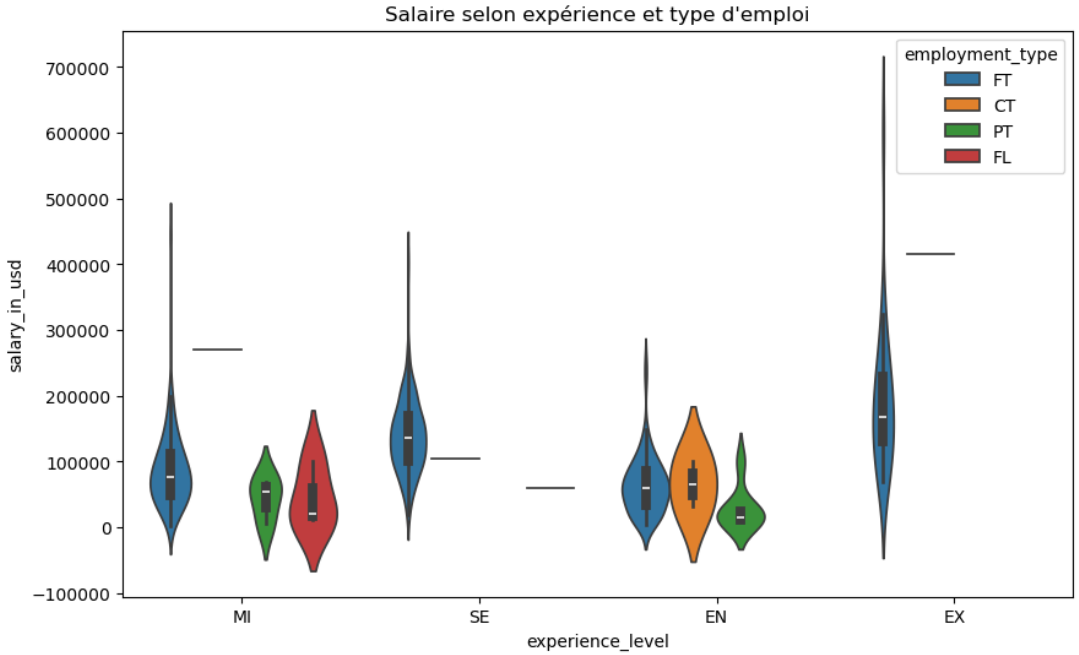



Le salaire varie selon la taille de l'entreprise et le type d'emploi. Les emplois à temps plein (FT) offrent globalement les salaires les plus élevés, surtout dans les grandes entreprises (L). Les contrats (CT) présentent aussi des salaires élevés mais avec une forte variabilité. Les emplois à temps partiel (PT) et freelance (FL) ont généralement des salaires plus faibles, quel que soit la taille de l'entreprise.

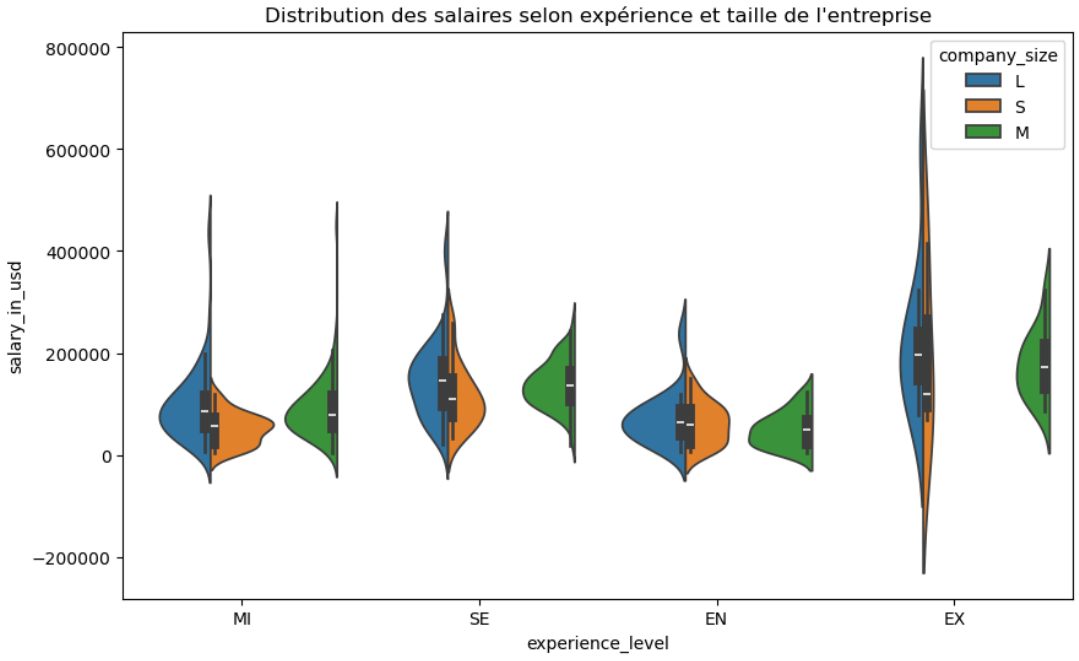



Ce graphique analyse la distribution des salaires en combinant le niveau d'expérience, le type d'emploi et la taille de l'entreprise. Les grandes entreprises concentrent les salaires les plus élevés, notamment pour les profils executives (EX) et seniors (SE) en contrat à temps plein (FT). Les contrats (CT) sont réservés aux grandes et moyennes entreprises, tandis que les petites entreprises n'emploient que des profils juniors à seniors en temps plein ou temps partiel, avec des salaires modestes. Les freelances (FL) restent rares et limités aux petites structures

### 4.3.2 Violin plot




Les temps pleins (FT) offrent les salaires les plus élevés et les plus dispersés, particulièrement pour les seniors et executives. Les contrats (CT) sont rares et limités aux profils MI et EX. Les temps partiels (PT) et freelances (FL) sont concentrés sur les bas salaires, principalement pour les juniors et mi-level.




Les grandes entreprises (L) affichent une distribution étalée pour les seniors et executives, avec des salaires atteignant 600 000 USD. Les petites entreprises (S) ont des violons resserrés, concentrés entre 50 000 et 150 000 USD pour tous les niveaux. Les entreprises moyennes (M) occupent une position intermédiaire. Seules les grandes entreprises présentent des executives (EX) avec une forte variabilité salariale.




Ce graphique confirme que les grandes entreprises concentrent les salaires les plus élevés, avec des profils executives (EX) et seniors (SE) en temps plein (FT) atteignant des niveaux très hauts. Les contrats (CT) apparaissent uniquement dans les grandes et moyennes entreprises, principalement pour les mi-level (MI). Les petites entreprises n'emploient que des temps pleins (FT) et temps partiels (PT) sur des profils juniors à seniors, avec des salaires faibles et resserrés. Les freelances (FL) sont rares et limités aux petites structures.

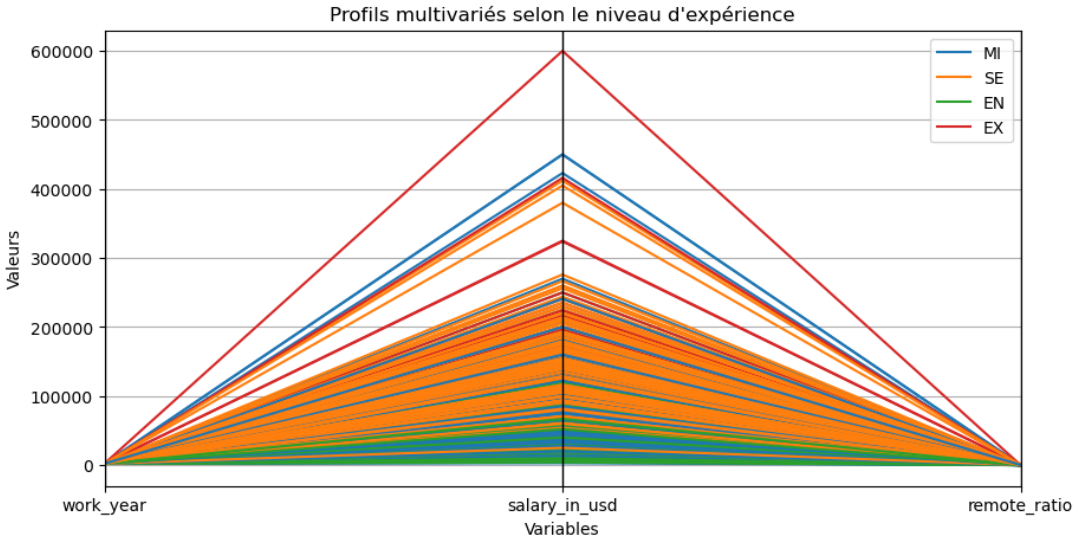
### 4.3.3 Décisions

- Les décisions doivent tenir compte de plusieurs facteurs combinés.
- Les profils expérimentés doivent être orientés vers les grandes entreprises et les emplois à temps plein, où les salaires sont les plus élevés.
- Le recrutement doit être adapté selon le niveau d'expérience : les profils juniors vers les petites entreprises et les profils intermédiaires vers les entreprises moyennes.
- Les emplois à temps plein sont à privilégier pour assurer une meilleure stabilité et une rémunération plus élevée.
- Les contrats à durée déterminée peuvent être utilisés pour des missions spécifiques avec une rémunération intermédiaire, tandis que les emplois à temps partiel et freelance doivent être limités aux situations nécessitant plus de flexibilité.
- Enfin, les stratégies de recrutement doivent intégrer simultanément l'expérience, la taille de l'entreprise et le type d'emploi.

## 4.4 Analyse des profils multivariés (Parallel Coordinates)

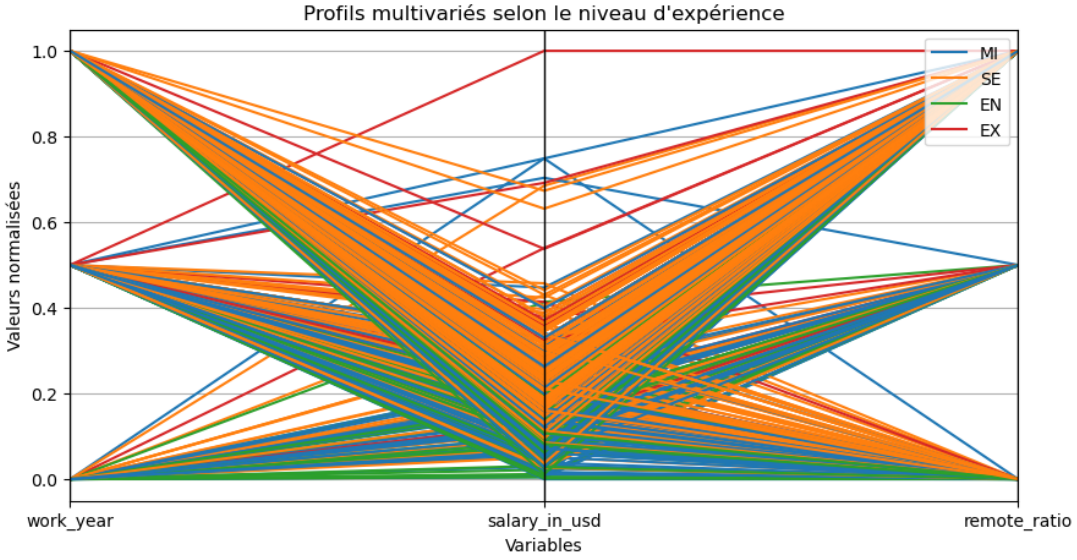
Le diagramme de coordonnées parallèles est une méthode de visualisation multivariée qui permet de représenter plusieurs variables numériques simultanément, chaque observation étant tracée sous forme d'une ligne reliant les axes. Dans ce graphique, l'objectif est de comparer les profils des individus selon plusieurs variables (work_year, salary_in_usd, remote_ratio) en fonction du niveau d'expérience (experience_level). Cela permet d'identifier des tendances, notamment l'influence de l'expérience sur le salaire, ainsi que de visualiser les similarités ou différences entre les différents groupes.

### 4.4.1 Sans normalisation



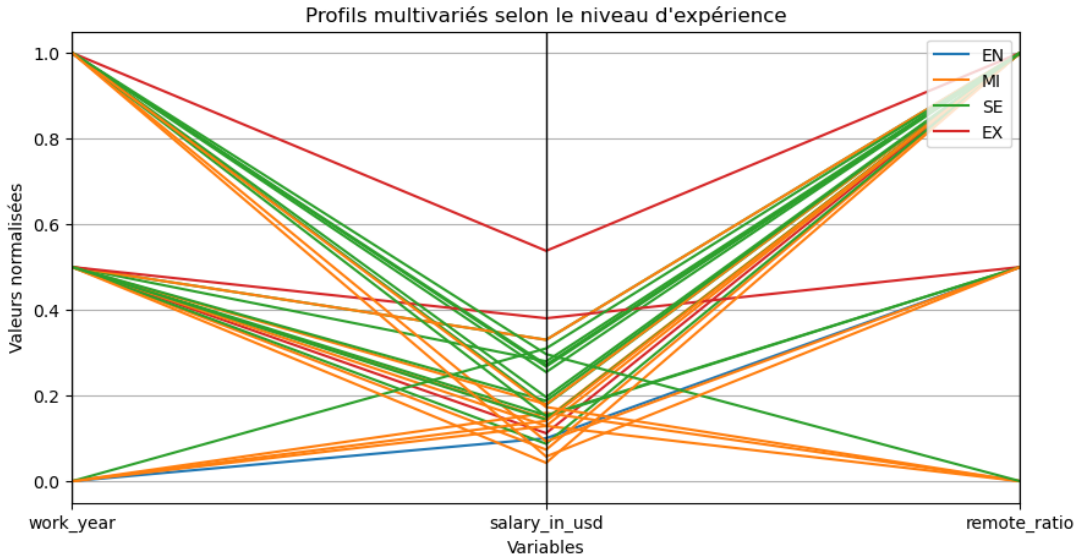

Le salaire augmente avec le niveau d'expérience, tandis que le télétravail et l'année ont peu d'impact visible. Cependant, l'absence de normalisation rend l'analyse moins précise.

### 4.4.2 Après normalisation




Après normalisation, toutes les variables sont mises sur la même échelle, ce qui permet une comparaison plus pertinente. On observe que le salaire (salary_in_usd) reste globalement plus élevé pour les niveaux d'expérience supérieurs, ce qui confirme l'influence de l'expérience sur la rémunération. En revanche, le taux de télétravail (remote_ratio) est très dispersé et ne montre pas de relation claire avec l'expérience. De plus, la variable work_year varie peu et n'apparaît pas comme déterminante. Enfin, le chevauchement des lignes indique que certains profils présentent des caractéristiques similaires malgré leur différence de catégorie

### 4.4.3 Echantillon




Après normalisation et réduction de l'échantillon, le graphique devient plus lisible et permet une meilleure comparaison des variables. On observe que les niveaux d'expérience élevés (notamment EX et SE) ont généralement des valeurs plus importantes en termes de salaire, ce qui confirme que l'expérience influence positivement la rémunération. En revanche, le taux de télétravail (remote_ratio) reste très variable pour tous les profils, sans tendance claire selon l'expérience. La variable work_year montre peu de différence entre les individus. Enfin, même si certaines tendances apparaissent, le croisement des lignes indique que les profils ne sont pas totalement distincts et présentent des caractéristiques parfois similaires.

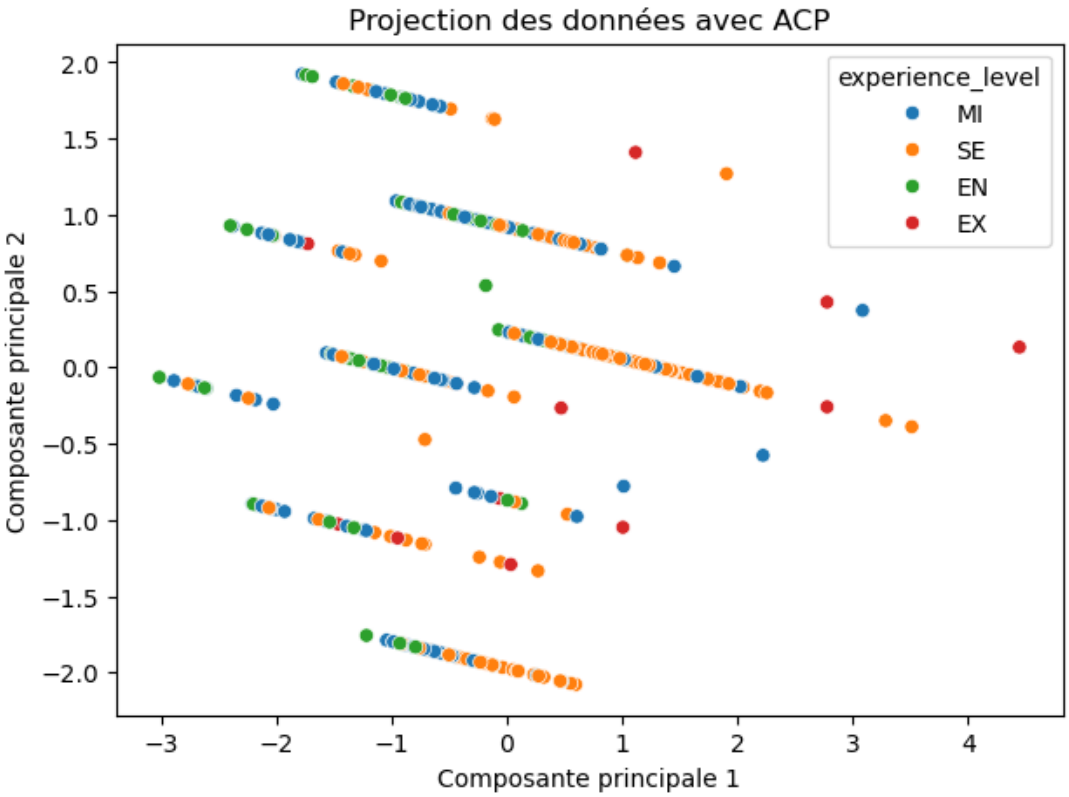
### 4.4.4 Décisions

— Mettre en place des programmes de formation et de promotion interne pour faire évoluer les juniors vers des postes mieux rémunérés.
— Augmenter les salaires ou proposer des avantages compétitifs pour attirer et retenir les profils seniors (SE, EX).
— La normalisation des données doit être appliquée pour des analyses fiables.

## 4.5 Simplifier les données complexes

### 4.5.1 ACP avec 2 composantes (2D)

Variance expliquée : [0.41880966 0.30894758]




| | salary_in_usd | remote_ratio | work_year |
|---|---|---|---|
| PC1 | 0.643082 | 0.503151 | 0.577309 |
| PC2 | -0.114030 | 0.808377 | -0.577515 |

TABLE 4.1 – Contribution des variables (PC1 et PC2)

— PC1 : 41.88 %
— PC2 : 30.89 %
— Total : 72.78 %

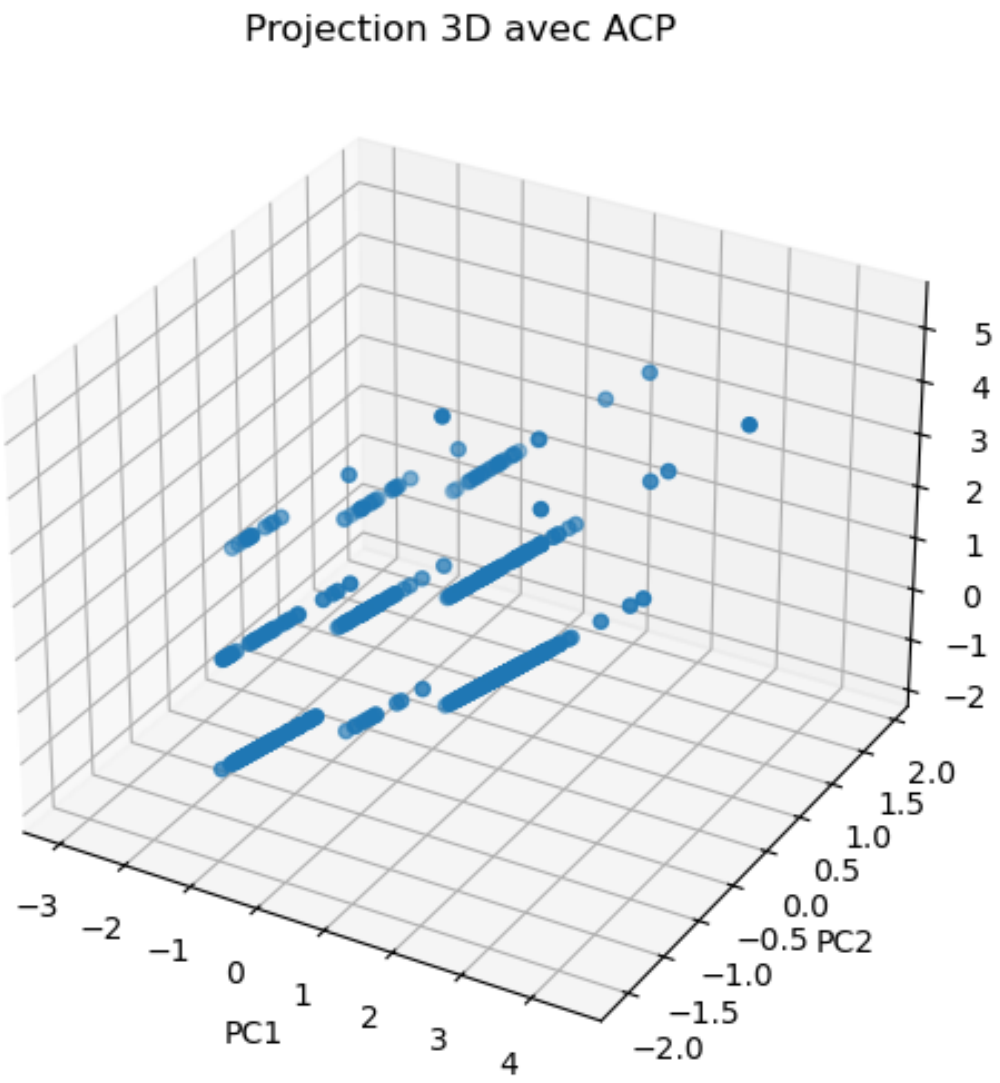
Cela signifie qu'on perd environ 27 % de l'information en passant à 2 dimensions.

— Présence de bandes diagonales parallèles, ce qui indique que certaines variables sont corrélées.
— Une dispersion des points selon PC1.
— Les niveaux d'expérience (Mid level, Senior, Entry, Executive) sont mélangés.

La projection en 2 dimensions permet de visualiser une structure globale des données. On observe une séparation partielle des individus selon leurs caractéristiques, notamment le niveau d'expérience et le salaire. Les profils avec des salaires élevés et une expérience importante ont tendance à se regrouper dans certaines zones, tandis que les profils juniors sont concentrés ailleurs. Cependant, la séparation reste limitée, ce qui indique que deux composantes ne suffisent pas à capturer toute la complexité des données.

### 4.5.2 Visualisation avec 3 composantes (3D)

Variance expliquée : [0.41880966 0.30894758 0.27224275]




| | work_year | salary_in_usd | remote_ratio |
|---|---|---|---|
| PC1 | 0.643082 | 0.503151 | 0.577309 |
| PC2 | -0.114030 | 0.808377 | -0.577515 |
| PC3 | 0.757260 | -0.305559 | -0.577226 |

TABLE 4.2 – Contribution des variables aux composantes principales

— PC1 : 41.88 %
— PC2 : 30.89 %
— PC3 : 27.22 %
— Total : 99.99 %
— La représentation 3D est meilleure que la 2D.
— Présence de bandes parallèles.
— Les données suivent des relations linéaires.

## Valeurs atypiques

— Présence de points isolés.
— Certains points sont éloignés du groupe principal.

L'ajout d'une troisième composante améliore la représentation des données et permet une meilleure séparation des groupes. Les clusters deviennent plus visibles, notamment entre les différents niveaux d'expérience et niveaux de salaire. On distingue plus clairement les profils à forte rémunération, souvent associés à une expérience élevée, ainsi que les profils moins expérimentés avec des salaires plus faibles. Cela montre que la structure des données est multidimensionnelle et qu'une représentation en 3D est plus adaptée pour capturer les relations entre variables.

### 4.5.3 Décisions

- Le niveau d'expérience est le facteur principal qui différencie les salaires, il doit être priorisé dans les décisions RH
- Les profils seniors et executives doivent être ciblés car ils correspondent aux salaires les plus élevés
- La visualisation en 3D (ACP) est plus pertinente pour analyser des données complexes et doit être privilégiée
- La réduction de dimension permet de simplifier l'analyse tout en conservant l'essentiel de l'information
- Il est recommandé d'utiliser les composantes principales pour améliorer les modèles prédictifs et la prise de décision
- Les entreprises doivent adapter leur stratégie en fonction des groupes de profils identifiés (junior, intermédiaire, senior)

# Chapitre 5

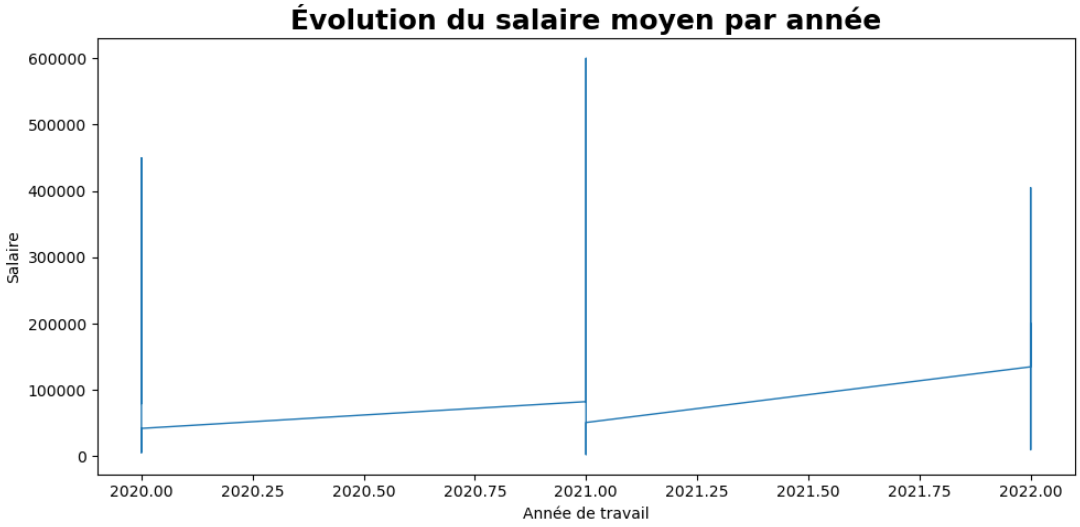
# Visualisation Temporelle-Geospatiale

## 5.1 visualisation Temporelle

La visualisation temporelle permet d'analyser l'évolution des données au fil du temps. Elle est essentielle pour identifier les tendances, détecter des variations, des cycles ou des anomalies. Dans cette partie, nous utilisons principalement des courbes et des séries temporelles afin d'observer l'évolution des salaires et d'autres variables au cours des années.

### 5.1.1 Suivre l'évolution d'une variable dans le temps

**Courbe simple**

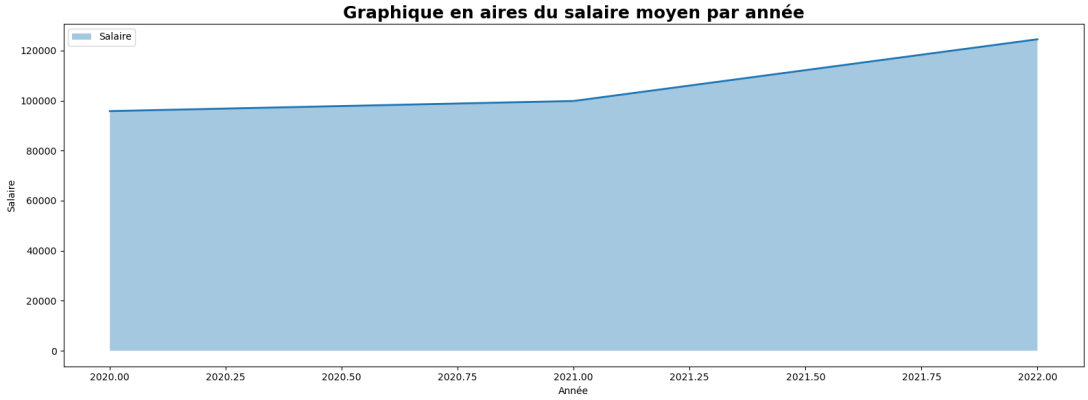



Le graphique montre l'évolution du salaire moyen entre 2020 et 2022.

— On observe une augmentation globale des salaires.
— Entre 2020 et 2021, l'augmentation est modérée.
— Entre 2021 et 2022, la croissance devient plus importante.
— La présence de valeurs très élevées (outliers) indique que certains salaires élevés influencent la moyenne.

Cette évolution suggère une augmentation de la demande en compétences et une valorisation progressive des profils.

### Graphique en aires




Le graphique en aires met en évidence l'évolution du salaire moyen au fil des années.

— La surface augmente de manière continue , cela confirme une croissance stable.

— La montée est plus rapide après 2021, ce qui traduit une accélération des salaires.

Ce type de graphique insiste sur le volume global et la tendance générale, plutôt que sur les variations ponctuelles.

L'analyse temporelle des salaires (2020–2022) met en évidence une tendance haussière continue du salaire moyen. Cette augmentation est progressive entre 2020 et 2021, puis s'accélère nettement entre 2021 et 2022, ce qui traduit une forte dynamique du marché de l'emploi, notamment dans les métiers liés à la data. Cependant, la présence de valeurs extrêmes (salaires très élevés) indique une forte hétérogénéité dans les rémunérations. Cela signifie que la moyenne peut être influencée par quelques salaires atypiques, et ne reflète pas toujours la réalité globale.

En résumé, le marché est :

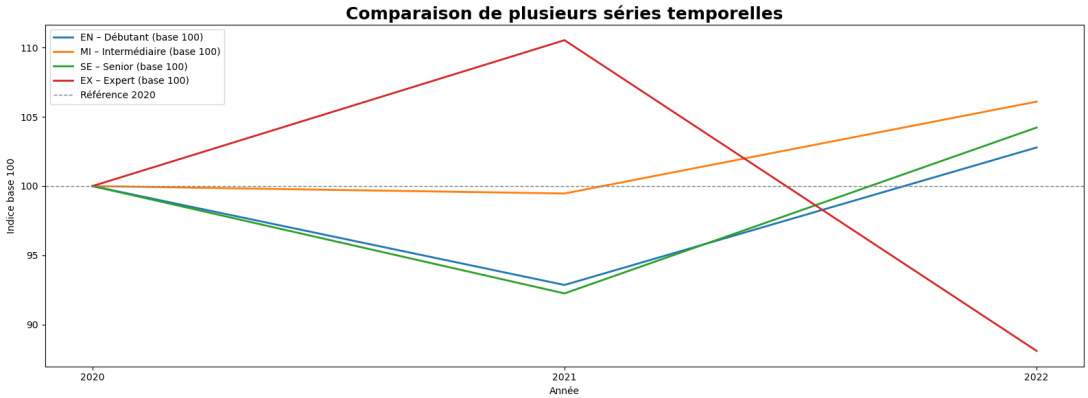
— en croissance

— en accélération récent

— inégalement réparti (dispersion importante des salaires)

## 5.1.2 Comparer plusieurs séries temporelles

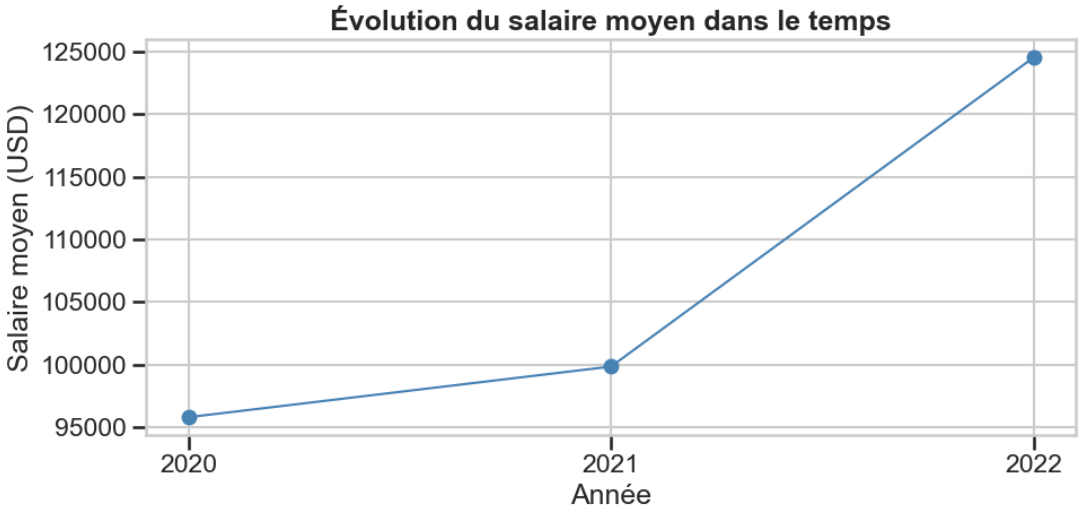
### Courbe multiples



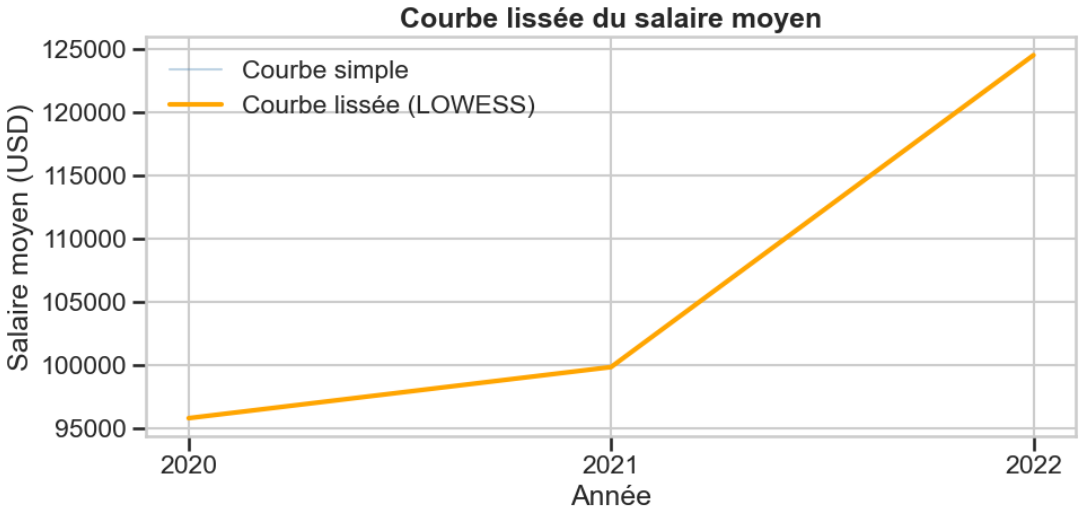

les salaires des débutants ont augmenté plus rapidement que ceux des seniors et experts, ce qui peut indiquer une forte demande pour les profils juniors dans le domaine de la data science. et que les entreprises sont prêtes à offrir des salaires compétitifs pour attirer

les talents débutants. décision : les débutants ont vu une croissance plus rapide de leurs salaires, ce qui peut être un signe positif pour les personnes entrant dans le domaine de la data science. Cependant, il est important de noter que les seniors et experts continuent d'avoir des salaires élevés, même si leur taux de croissance est plus lent.

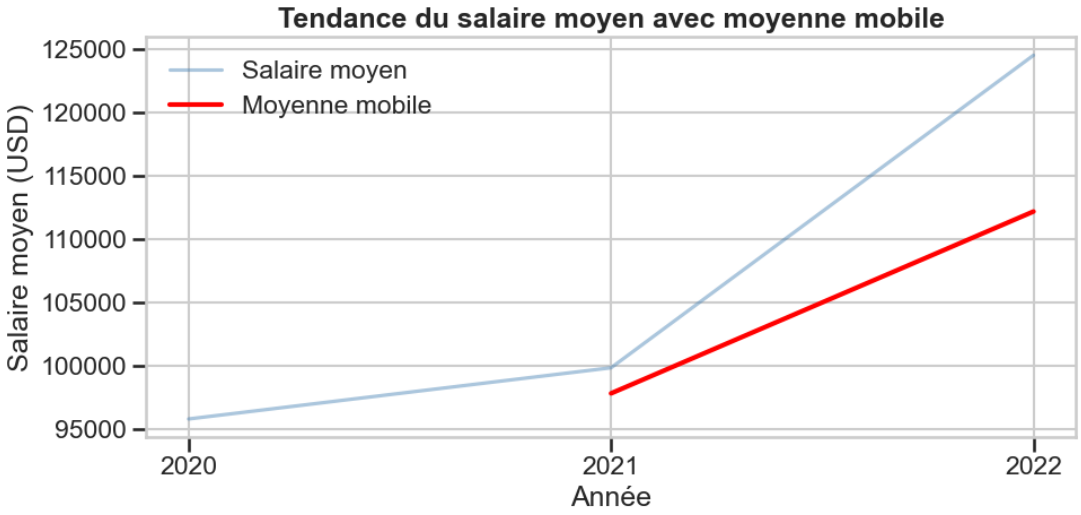
### 5.1.3 Mettre en évidence une tendance générale

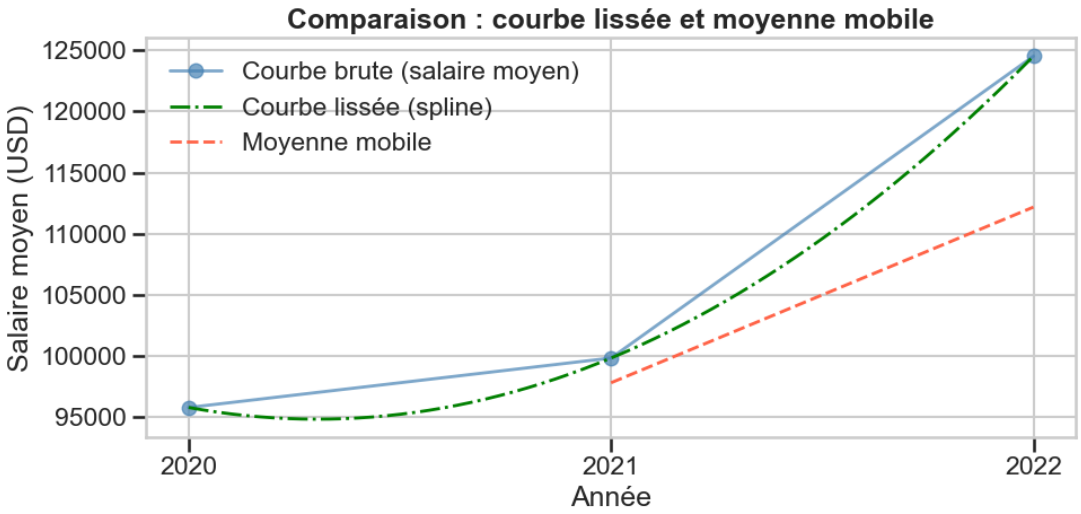



**Courbe lissée**



### Moyenne mobile




Remarque : Pour le graphique de comparaison finale, nous avons utilisé la courbe lissée Spline à la place de LOWESS, car avec seulement 3 points de données (2020, 2021, 2022), LOWESS suit exactement la courbe brute et ne montre pas de différence visible. La Spline permet de mieux distinguer les trois courbes et rend le graphique plus lisible.

Courbe brute : le salaire moyen réel passe de 95 000 USD en 2020 à 125 000 USD en 2022, avec une accélération forte entre 2021 et 2022.

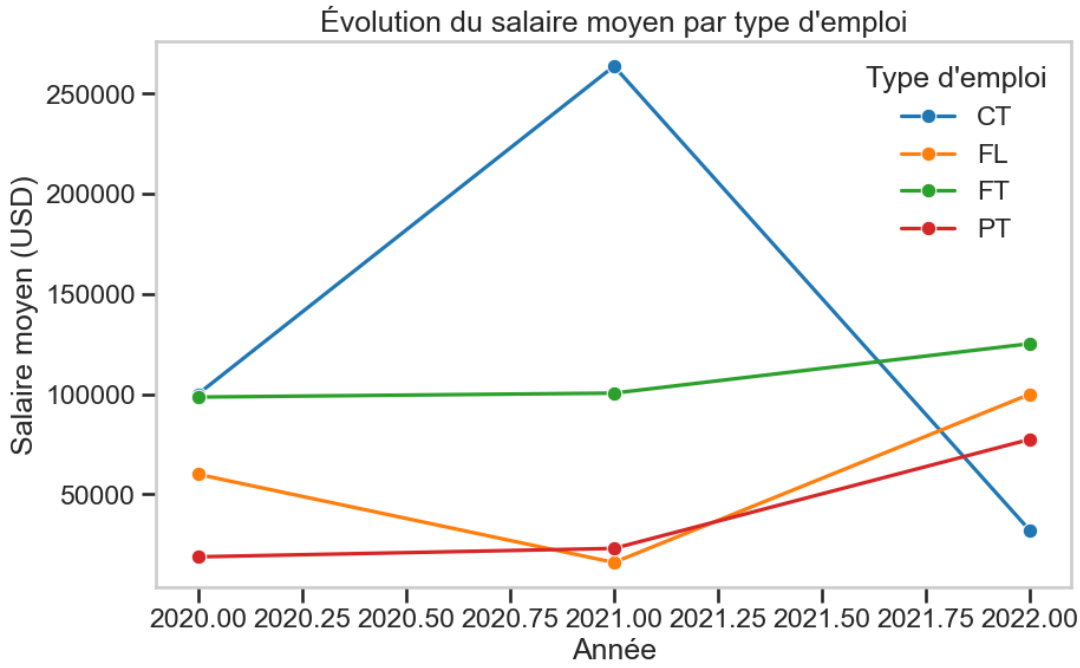
Courbe lissée : suit presque exactement la courbe brute, ce qui confirme qu'il n'y a pas de fluctuations — la tendance est régulière et stable.

Moyenne mobile : toujours en dessous des deux autres courbes car elle retarde légèrement, mais confirme sans ambiguïté la tendance haussière générale.

Les 3 courbes racontent la même histoire : les salaires en Data Science augmentent continuellement et fortement.

### 5.1.4 Détecter une saisonnalité ou des cycles

**Courbe par période**




— Le salaire moyen évolue différemment selon le type d'emploi.
— On observe une forte variation pour certains types :
  - Le type emploi en contrat temporaire connaît un pic important en 2021 puis une baisse en 2022.
  - Le type emploi à temps plein reste relativement stable avec une légère augmentation.
— Les types emploi à temps partiel et travailleur indépendant montrent des niveaux de salaires plus faibles mais en progression en 2022.
— Il n'y a pas de tendance régulière (pas de saisonnalité claire).

Les salaires évoluent de manière irrégulière selon le type d'emploi, sans cycle stable.

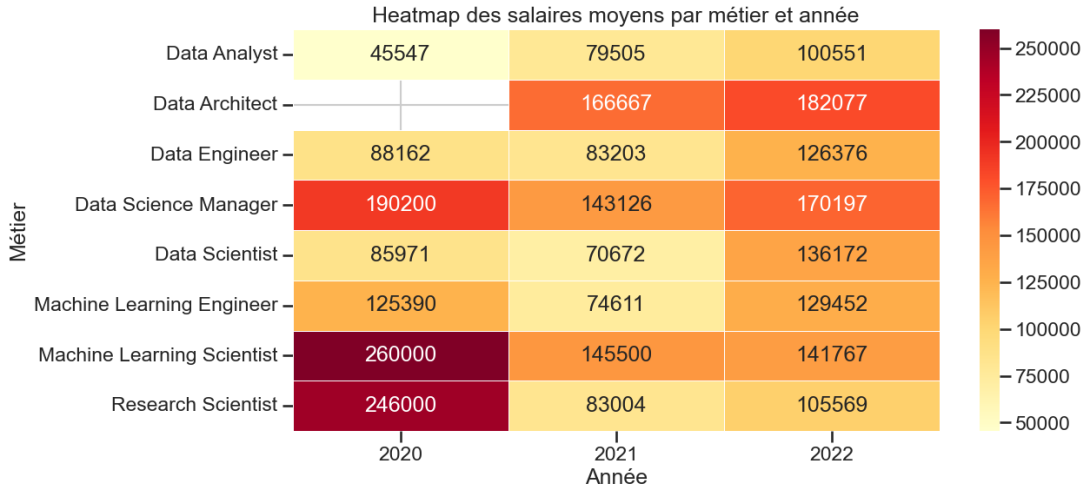
### Boxplot




— La médiane des salaires augmente progressivement de 2020 à 2022.
— La dispersion des salaires devient plus importante au fil des années.
— En 2022, les salaires sont plus étalés (écart plus grand).
— La présence de valeurs élevées indique des salaires très importants pour certains profils.

Le marché des salaires devient plus hétérogène avec une tendance globale à la hausse.

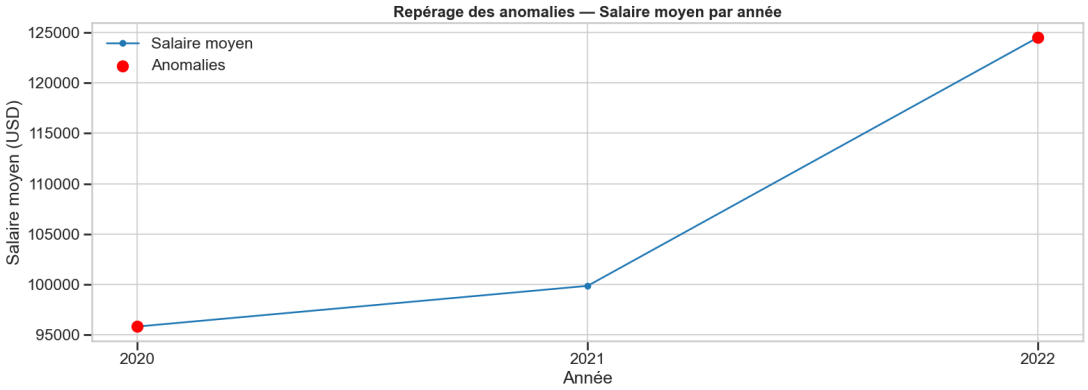
### Heatmap temporelle




— La médiane des salaires augmente progressivement de 2020 à 2022.
— La dispersion des salaires devient plus importante au fil des années :
— En 2022, les salaires sont plus étalés (écart plus grand).
— La présence de valeurs élevées indique des salaires très importants pour certains profils.

### 5.1.5 Repérer des anomalies

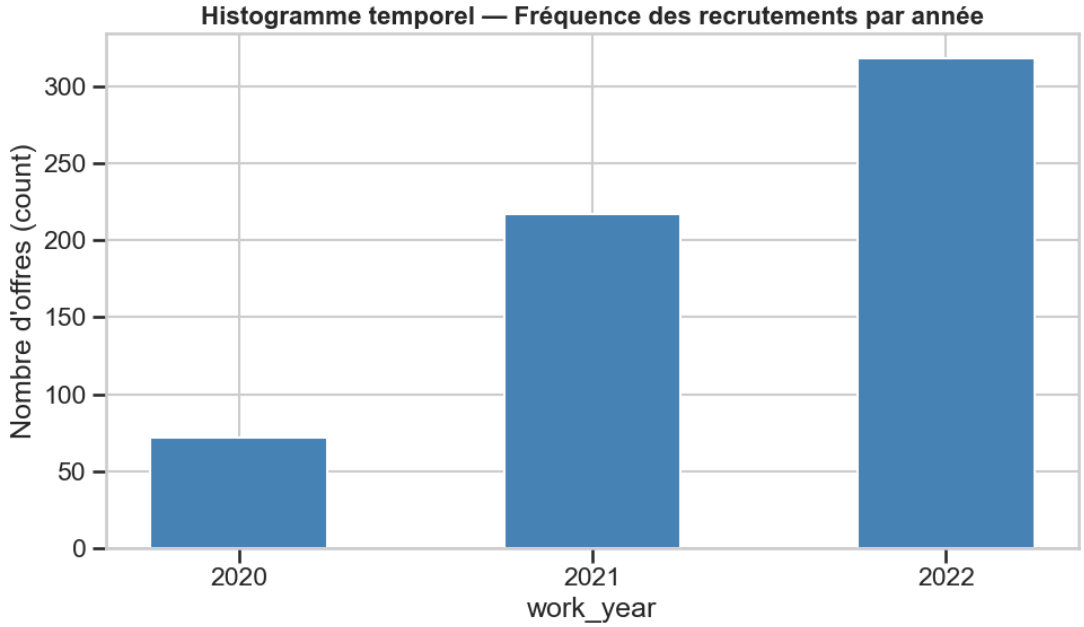
#### Courbe avec points marqués




Les années 2020 et 2022 présentent des anomalies, avec des salaires moyens plus élevés que la moyenne générale. Cela peut être dû à des facteurs tels que la pandémie de COVID-19, qui a entraîné une augmentation de la demande pour les professionnels de la data science, ou à des changements dans les politiques salariales des entreprises.

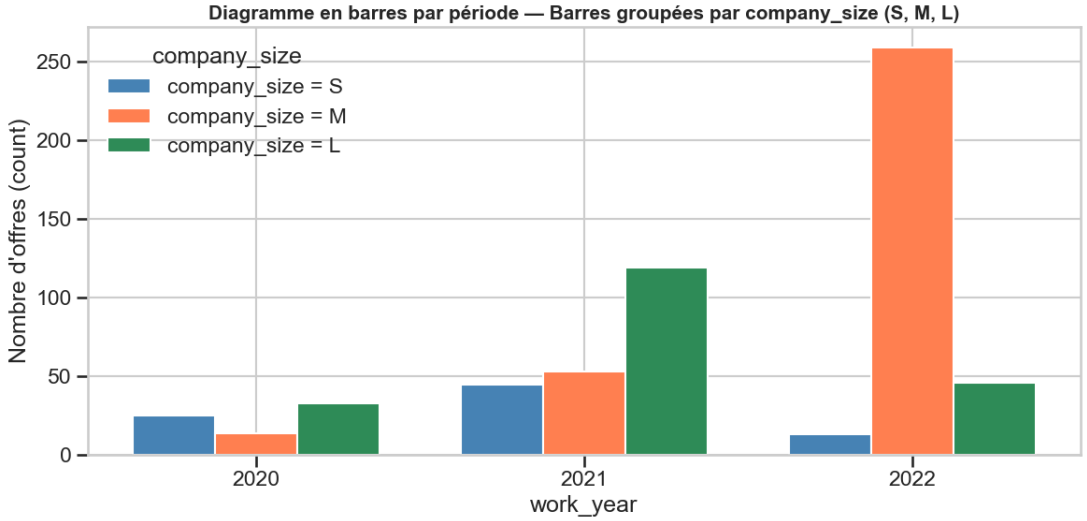
### 5.1.6 Analyser la fréquence et la répartition des événements dans le temps

#### Histogramme temporel




Le nombre d'offres dans les métiers de la data a connu une croissance continue et forte sur les trois années. Entre 2020 et 2021, les offres ont presque triplé, et entre 2021 et 2022, elles ont encore augmenté. Cette tendance reflète l'explosion de la demande en data science, notamment après la période COVID qui a accéléré la transformation numérique des entreprises.

**Diagramme en barres par période**




— 2020 : les grandes entreprises (L) dominent légèrement, avec une répartition assez équilibrée entre les trois tailles.
— 2021 : forte hausse généralisée, mais ce sont surtout les grandes entreprises (L = 119) qui recrutent massivement, elles captent plus de la moitié des offres.
— 2022 : renversement spectaculaire, les entreprises de taille moyenne (M) explosent à 259 offres, dépassant largement les grandes (46) et les petites (13). Cela indique une démocratisation du recrutement data vers des entreprises en pleine croissance.

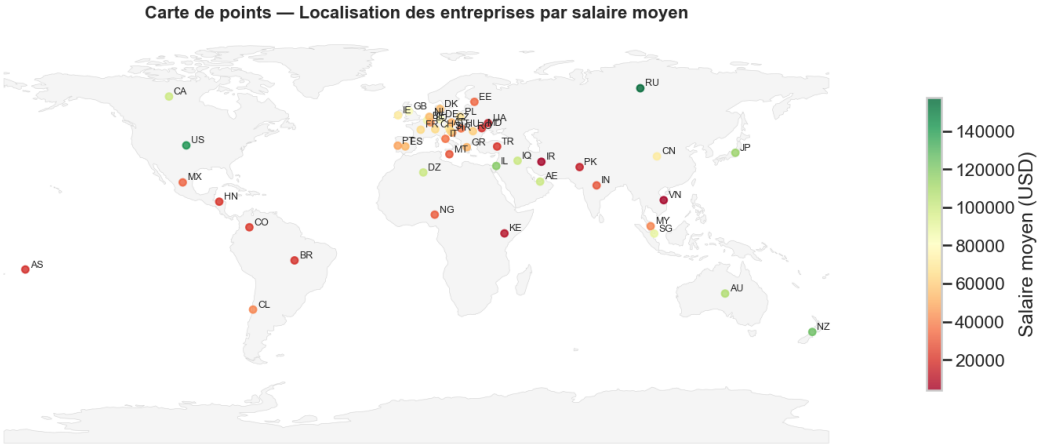
### 5.1.7 Décisions

— Les salaires en Data Science montrent une tendance globale à la hausse au fil des années, ce qui reflète une croissance du marché et une forte demande en compétences data.
— Les entreprises doivent adapter régulièrement leurs grilles salariales afin de rester compétitives face à l'évolution du marché.
— L'analyse temporelle montre que les années récentes offrent plus d'opportunités avec des salaires plus élevés, ce qui incite les candidats à cibler les marchés actuels plutôt que passés.
— La détection d'anomalies permet d'identifier des salaires exceptionnellement élevés ou faibles, ce qui peut orienter les décisions de recrutement ou d'audit salarial.
— L'absence de forte saisonnalité indique que le marché de la Data Science est stable et peu dépendant de cycles économiques courts.
— Il est stratégique pour les entreprises d'anticiper les tendances futures en se basant sur l'évolution passée afin d'optimiser leurs politiques RH et salariales.

## 5.2 visualisation Geopatiale

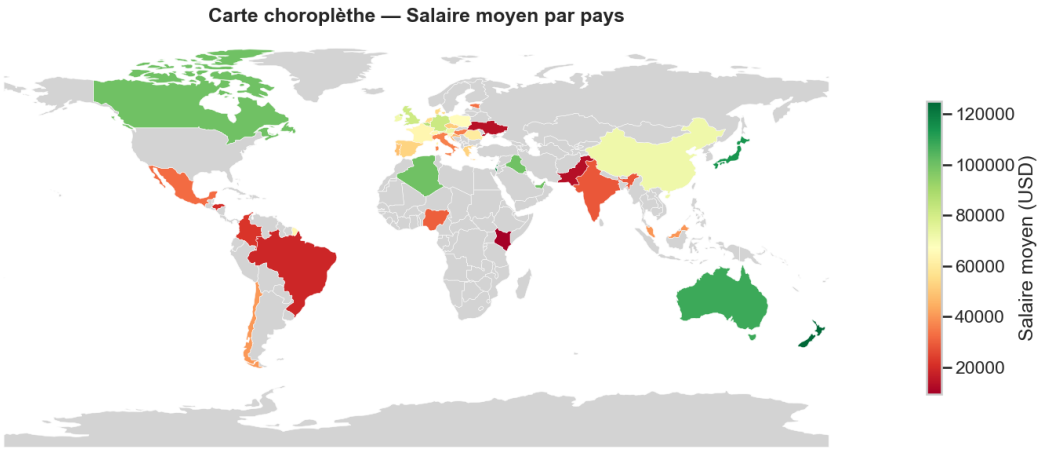
La visualisation géospatiale permet d'analyser la répartition des données dans l'espace géographique. Elle aide à identifier les zones où certains phénomènes sont plus concentrés et à comparer les différences entre régions ou pays. Dans cette partie, nous utilisons des cartes et des représentations spatiales afin d'étudier la distribution des salaires et des emplois en Data Science à l'échelle mondiale.

### 5.2.1 Localiser des objets ou événements dans l'espace



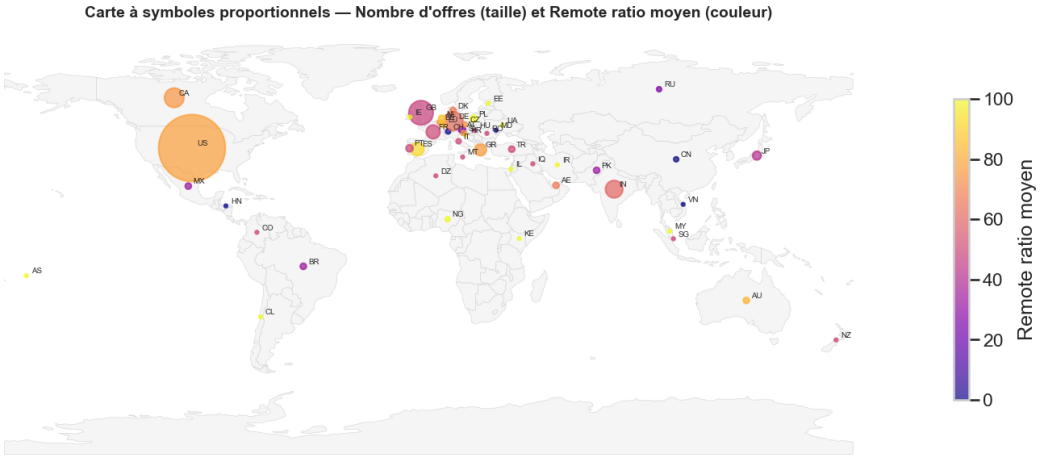

La carte montre la répartition géographique des salaires moyens à l'échelle mondiale. On observe de fortes disparités entre les pays. Les salaires les plus élevés se concentrent dans les pays développés, notamment en Amérique du Nord et en Océanie. À l'inverse, les salaires sont plus faibles dans les pays en développement, comme en Afrique et en Amérique du Sud. L'Europe présente des niveaux intermédiaires et relativement homogènes. Ces écarts s'expliquent par le niveau de développement économique, le coût de la vie et la demande en compétences.

### 5.2.2 Comparer des valeurs entre plusieurs zones géographiques




La carte choroplèthe révèle des disparités salariales importantes entre les pays. Les USA, Canada et Russie dominent avec des salaires supérieurs à 120 000 USD (vert foncé), suivis par l'Australie entre 80 000 et 120 000 USD (vert clair). La Chine et l'Europe se situent dans la moyenne mondiale entre 60 000 et 80 000 USD (jaune). L'Amérique du Sud et l'Inde affichent les salaires les plus faibles inférieurs à 40 000 USD (rouge). Les pays en gris n'ont pas de données disponibles.

### 5.2.3 Représenter l'intensité d'un phénomène en chaque lieu




— Les États-Unis dominent largement avec la plus forte intensité (plus grand cercle)
— L'Europe présente une forte concentration de pays avec des intensités moyennes
— Certains pays comme le Canada, l'Inde ou le Japon montrent des niveaux significatifs mais inférieurs aux États-Unis
— Plusieurs pays ont une faible intensité (petits cercles), indiquant une activité ou présence limitée
— Le type de travail varie fortement selon les pays, sans distribution uniforme
— Certaines régions combinent forte intensité et un taux élevé de travail à distance, ce qui peut indiquer une adoption importante de ce type de travail.
— Globalement,il existe une inégalité géographique importante dans la répartition du phénomène étudié

### 5.2.4 Détecter des concentrations ou zones denses

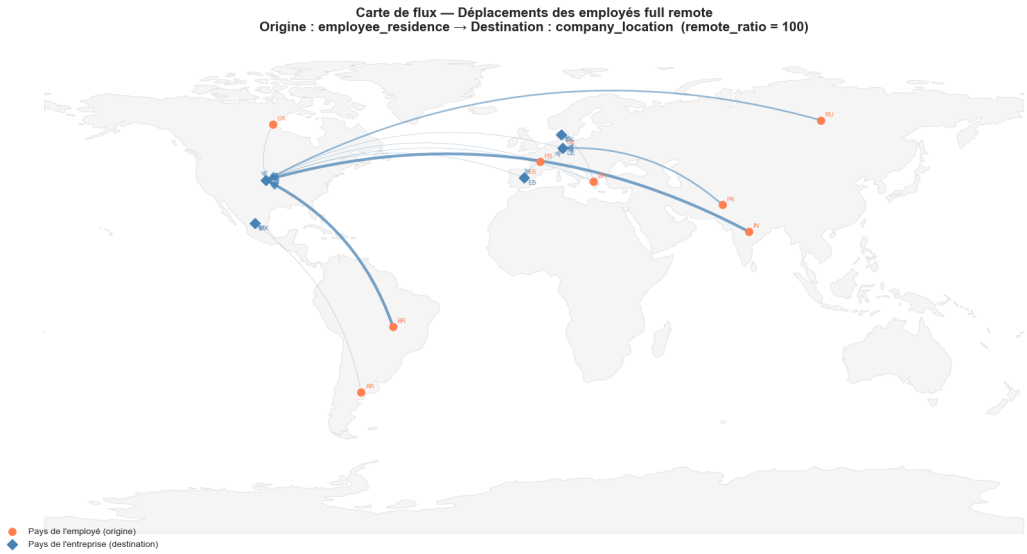



D'après la carte choroplèthe, on observe que les États-Unis ont la plus forte concentration d'employés dans le domaine de la data science, suivis par des pays comme le Royaume-Uni, l'Allemagne et l'Inde.

Cette répartition peut être liée à la taille des marchés technologiques, à la présence d'entreprises innovantes et à l'investissement dans les technologies de l'information dans

ces pays. En revanche, certains pays d'Afrique et d'Amérique du Sud montrent une faible densité d'employés, ce qui peut indiquer des opportunités de croissance dans ces régions.

### 5.2.5 Montrer des déplacements entre pays




— Les États-Unis (US) sont le centre de gravité absolu.
— Presque tous les arcs convergent vers US , c'est la principale destination des employés full remote.
— Les entreprises américaines recrutent massivement à l'international sans exiger de présence physique.
— Les pays d'origine sont très diversifiés géographiquement, On retrouve des employés venant de : Europe : CA (Canada), ES (Espagne), FR (France), DE (Allemagne) Amérique Latine : BR (Brésil), MX (Mexique), AR (Argentine) Asie : IN (Inde), PK (Pakistan), RU (Russie)
— Les flux les plus épais partent de CA, IN et BR vers US.
— L'épaisseur des arcs indique que le Canada, l'Inde et le Brésil sont les plus grands fournisseurs de talents data en full remote pour les entreprises américaines.
— Les destinations non-US sont rares , DE (Allemagne) et GB apparaissent comme destinations secondaires, mais avec des flux beaucoup plus faibles — l'Europe recrute peu en full remote cross-border comparé aux USA.

### 5.2.6 Décisions

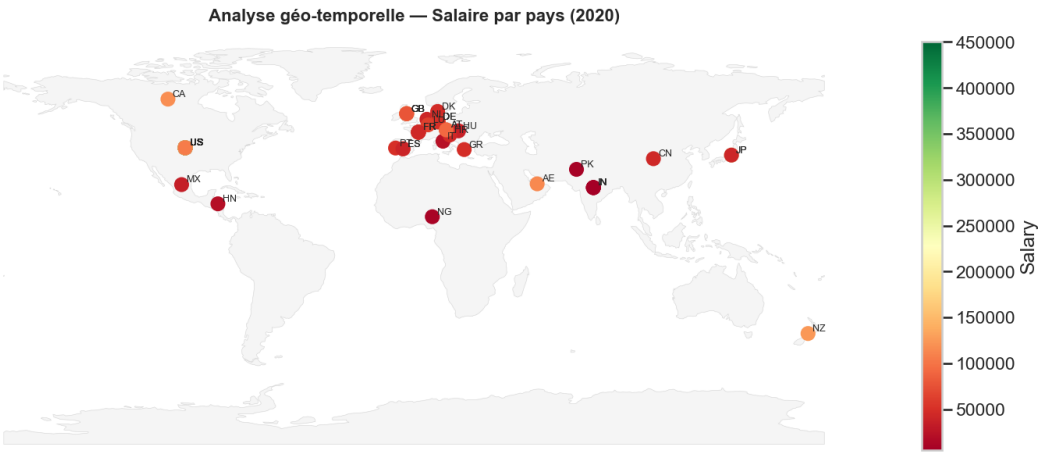
— Les États-Unis dominent largement en termes de salaires et d'opportunités, ce qui en fait le marché le plus attractif pour les professionnels de la Data Science.
— Les entreprises situées dans les pays développés offrent généralement des salaires plus élevés, ce qui montre l'importance du facteur géographique dans la rémunération.
— Les candidats doivent cibler les régions à forte valeur (USA, Europe de l'Ouest) pour maximiser leurs opportunités salariales.
— Les entreprises peuvent exploiter le travail à distance pour recruter des talents à l'international, même en dehors des zones à forte concentration.
— La concentration géographique des emplois indique que le marché est inégalement réparti, ce qui peut créer des opportunités dans les régions moins exploitées.

— L'analyse spatiale permet d'identifier les zones stratégiques pour l'implantation d'entreprises ou l'expansion d'activités data.

## 5.3 Visualisation GeoTemporelle

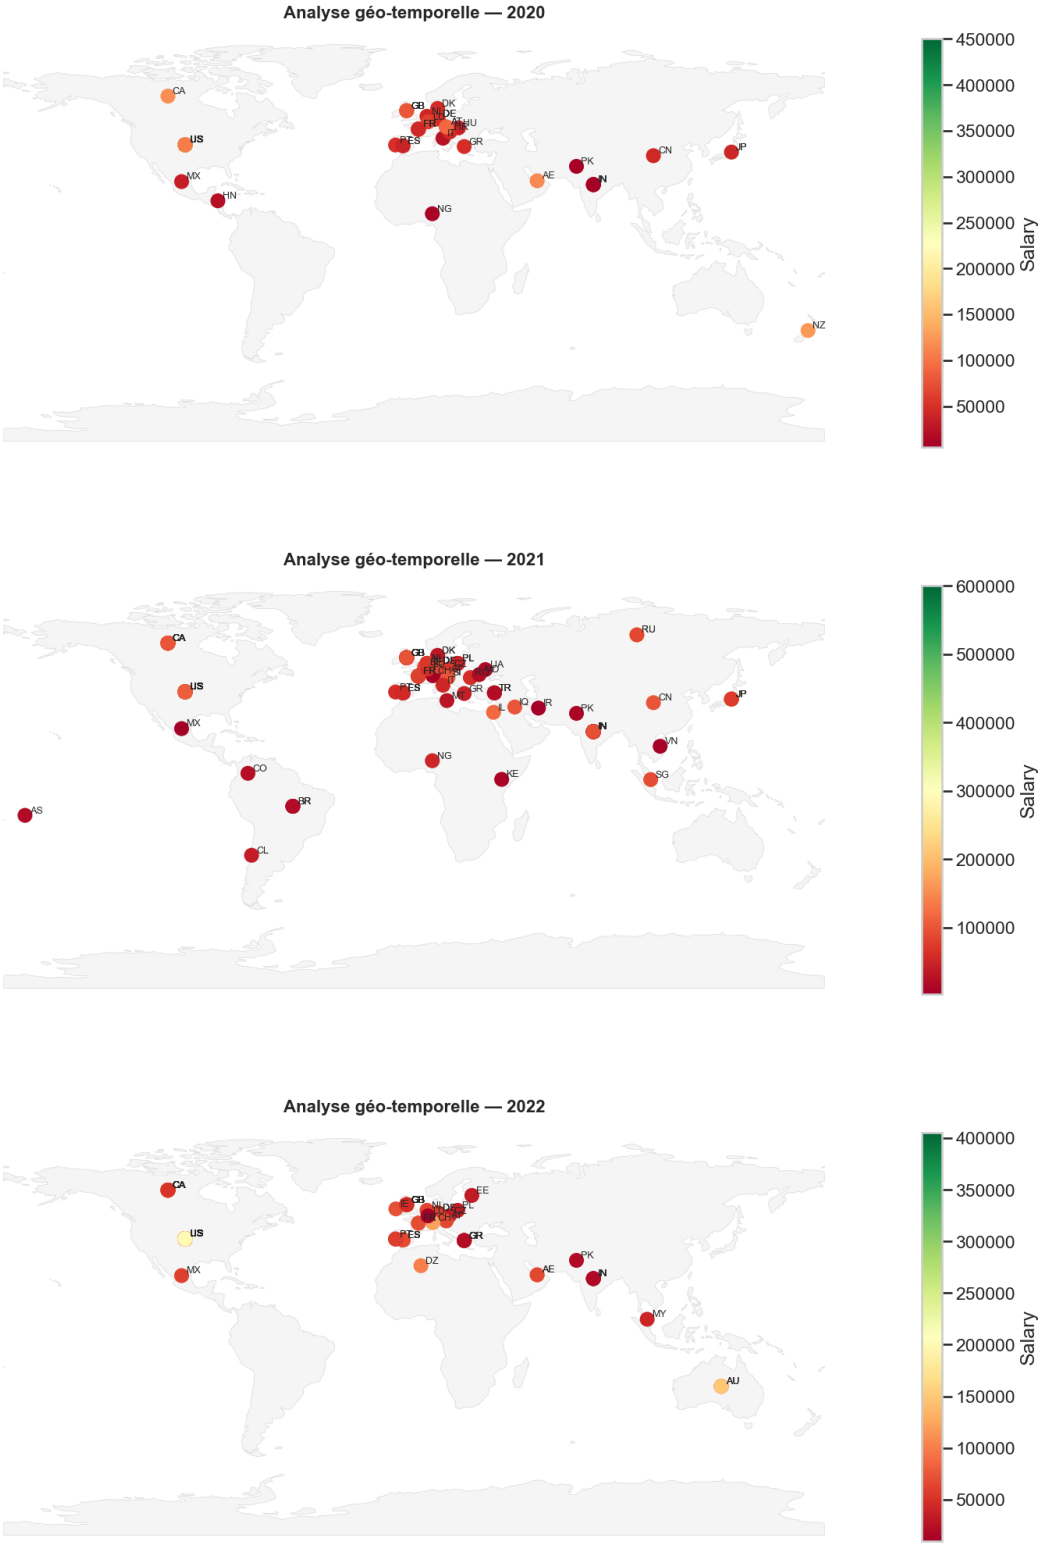
La visualisation géotemporelle combine les dimensions spatiale et temporelle afin d'analyser l'évolution des données dans le temps et dans l'espace. Elle permet de suivre les changements géographiques au fil des années et de mieux comprendre les dynamiques du marché. Dans cette partie, nous utilisons des cartes dynamiques et des courbes temporelles pour comparer les évolutions entre différents pays.

### 5.3.1 Carte pour une date




La carte géotemporelle pour l'année 2020 met en évidence une forte disparité des salaires entre les pays. Les salaires les plus élevés sont principalement concentrés aux États-Unis, qui se distinguent clairement comme le marché le plus attractif. Les pays européens présentent des niveaux de salaire intermédiaires, avec une certaine homogénéité entre eux. En revanche, plusieurs pays d'autres régions affichent des salaires plus faibles, ce qui souligne une inégalité géographique importante dans la rémunération en Data Science. On observe également que la majorité des pays représentés ont des salaires relativement modérés, avec peu de valeurs extrêmes élevées en dehors de quelques régions spécifiques. Cela montre que dès 2020, le marché était déjà dominé par certaines zones géographiques, notamment l'Amérique du Nord et l'Europe de l'Ouest.

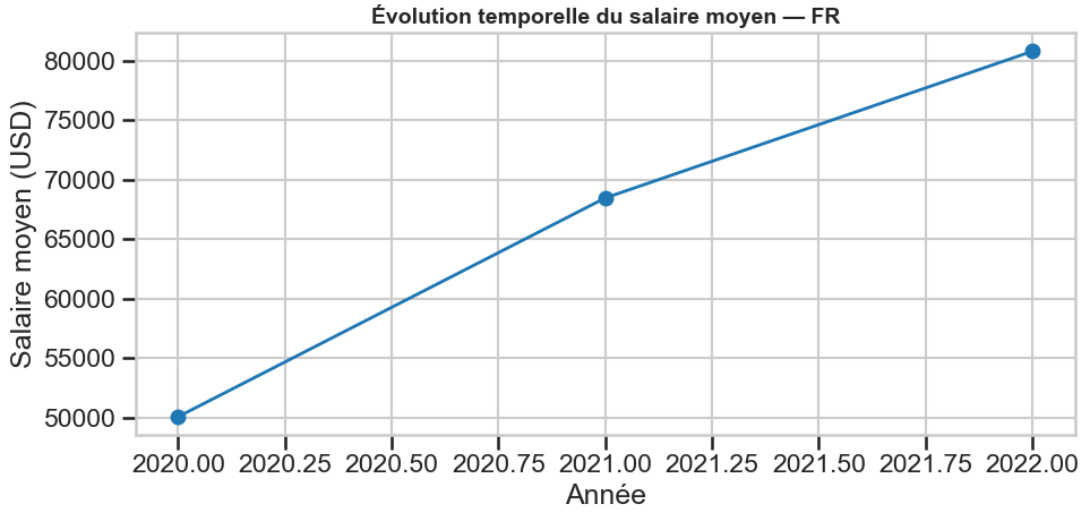
### 5.3.2 Comparer plusieurs dates

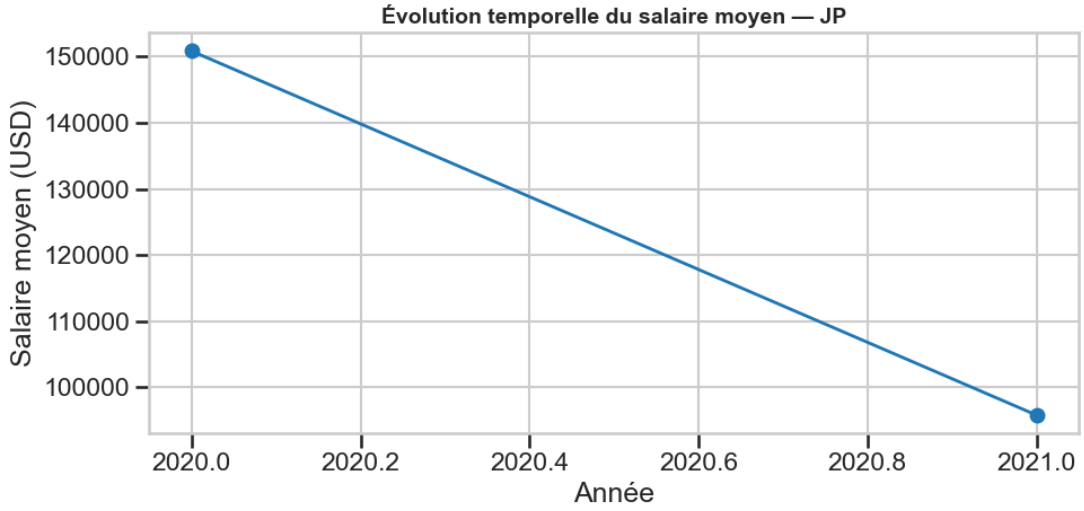


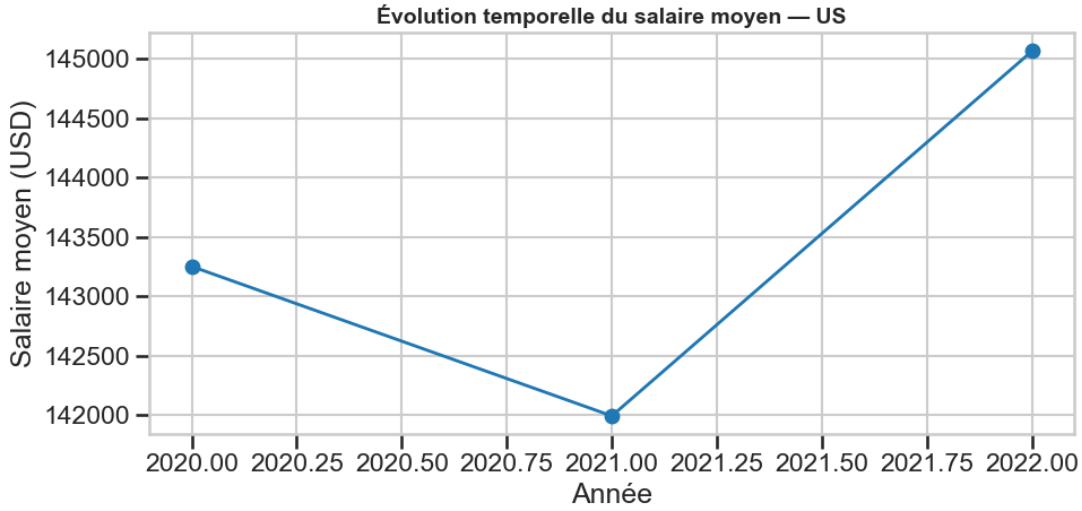

L'analyse géo-temporelle entre 2020, 2021 et 2022 met en évidence des évolutions différentes selon les pays. Les États-Unis maintiennent globalement les niveaux de salaires les plus élevés sur toute la période, avec une légère variation mais une position dominante constante. La France montre une progression notable entre 2020 et 2022, traduisant une croissance continue du marché. L'Espagne présente une évolution plus instable, avec une baisse en 2021 suivie d'une reprise en 2022. En revanche, le Japon affiche une diminution

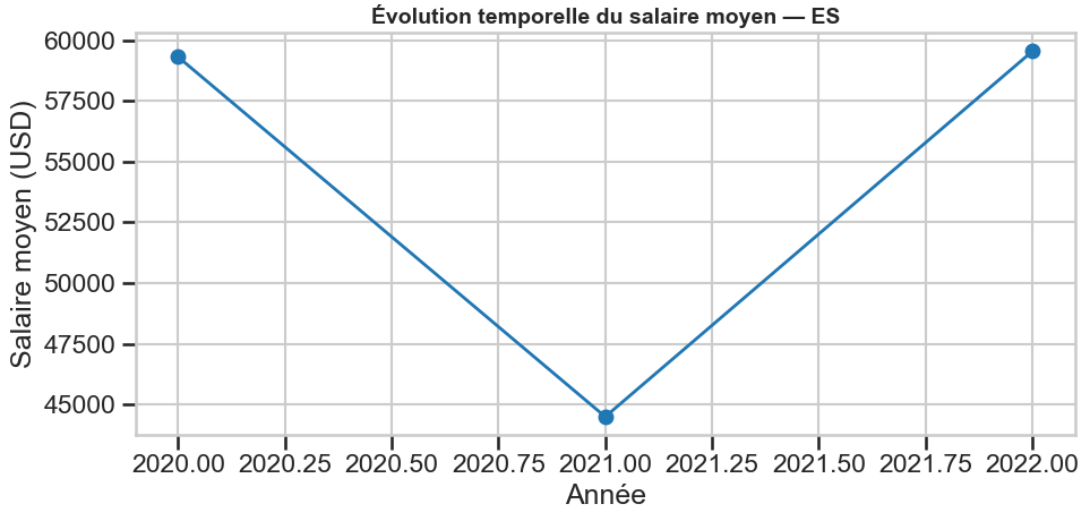
marquée entre 2020 et 2021 et n'apparaît plus en 2022, ce qui peut indiquer un manque de données ou une baisse d'activité. Globalement, cette comparaison révèle une tendance à la hausse dans certains pays, tandis que d'autres connaissent des fluctuations ou un recul, soulignant des dynamiques de marché différentes selon les régions.

### 5.3.3 Courbe temporelle pour pays






**France (FR)**

On observe une augmentation continue du salaire moyen en France entre 2020 et 2022. Le salaire passe d'environ 50 000 USD en 2020 à plus de 80 000 USD en 2022, avec une progression régulière chaque année. Cette évolution montre une amélioration stable du marché de l'emploi dans le domaine étudié, probablement liée à une demande croissante pour les compétences en data.

**Japon (JP)**

Contrairement aux autres pays, le Japon présente une diminution notable du salaire moyen entre 2020 et 2021, passant d'environ 150 000 USD à moins de 100 000 USD. Cette baisse peut indiquer une réduction de la demande, un changement dans la structure des postes, ou une variation dans les profils recrutés. L'absence de données pour 2022 limite cependant l'analyse complète.

**États-Unis (US)**

Les États-Unis montrent une légère fluctuation suivie d'une hausse. Après une petite baisse entre 2020 et 2021, le salaire moyen augmente pour atteindre environ 145 000 USD en 2022. Cela traduit un marché globalement stable avec une tendance à la hausse, confirmant la position dominante des États-Unis dans les métiers de la data.

**Espagne (ES)**

L'Espagne présente une évolution en forme de "V". Le salaire moyen diminue entre 2020 et 2021 (jusqu'à environ 45 000 USD), puis remonte en 2022 pour atteindre presque

son niveau initial (près de 60 000 USD). Cette variation peut refléter une instabilité temporaire du marché, suivie d'une reprise.

Cette analyse géotemporelle permet d'identifier les marchés les plus attractifs. Les États-Unis et la France apparaissent comme des zones à fort potentiel, tandis que d'autres pays nécessitent une approche plus prudente.

### 5.3.4 Décisions

- L'évolution des salaires varie selon les pays, ce qui montre que la dynamique du marché n'est pas uniforme à l'échelle mondiale.
- Certains pays affichent une croissance rapide des salaires, ce qui en fait des marchés émergents attractifs pour les professionnels.
- Les États-Unis restent dominants dans le temps, confirmant leur position de leader dans le domaine de la Data Science.
- L'analyse combinée espace-temps permet d'identifier les régions où la croissance est la plus forte et d'anticiper les futurs pôles de développement.
- Les entreprises doivent adapter leur stratégie en fonction de l'évolution géographique du marché pour rester compétitives.
- Les candidats peuvent utiliser ces tendances pour choisir le meilleur moment et le meilleur pays pour évoluer professionnellement.

# Chapitre 6

# Conclusion

Ce projet a permis d'analyser en profondeur les salaires dans le domaine de la Data Science à travers différentes techniques de visualisation de données. Les résultats obtenus mettent en évidence plusieurs facteurs clés influençant la rémunération.

Tout d'abord, le niveau d'expérience apparaît comme le facteur le plus déterminant, avec une augmentation significative des salaires pour les profils Senior et Executive. Ensuite, la localisation géographique joue un rôle majeur, les salaires les plus élevés étant principalement observés aux États-Unis et dans les grandes entreprises.

Par ailleurs, le travail à distance, bien qu'il ne présente pas une corrélation forte avec le salaire, est souvent associé aux opportunités les mieux rémunérées, notamment pour les profils expérimentés. De plus, les emplois à temps plein dominent largement les postes les mieux payés, confirmant leur importance dans la structure du marché.

L'analyse temporelle montre également une tendance à la hausse des salaires au fil des années, traduisant la croissance continue du secteur de la Data Science. Cependant, les corrélations observées restent globalement faibles, ce qui indique que la rémunération dépend d'un ensemble complexe de facteurs interdépendants.

Sur le plan stratégique, ces résultats suggèrent que les entreprises doivent adapter leurs politiques salariales pour rester compétitives, investir dans le développement des compétences et tirer parti du travail à distance pour attirer les talents. De leur côté, les professionnels ont intérêt à développer leur expérience et à s'orienter vers des marchés et des structures offrant de meilleures opportunités de rémunération.

En conclusion, ce projet démontre l'importance de la visualisation des données dans la compréhension des phénomènes complexes et dans l'aide à la prise de décision, tout en mettant en évidence les dynamiques actuelles du marché de la Data Science.